

Instrukcja uruchomienia:

Instalacja oprogramowania:

By przygotować środowisko do pracy z zaprojektowanym systemem należy zainstalować niezbędne oprogramowanie, w tym:

- PostgreSQL
- PowerBI
- Python (3.12 lub nowsza)

Następnie należy zainstalować biblioteki python niezbędne do poprawnego działania systemu. W tym celu za pomocą wiersza poleceń należy wykonać komendę:

```
pip install -r requirements.txt
```

Zainstaluje ona biblioteki zapisane w pliku tekstowym requirements.txt, w których skład wchodzi:

- pandas
- requests
- psycopg2
- pyarrow
- tqdm
- scikit-learn
- numpy

Utworzenie pustej bazy danych:

W celu utworzenia pustej bazy danych należy w pierwszej kolejności zalogować się do postgres używając narzędzia psql, które poprosi o hasło utworzone podczas instalacji oprogramowania PostgreSQL. W celu uruchomienia psql należy w cmd wpisać:

```
psql -U postgres
```

Następnie należy wykonać polecenie:

```
CREATE DATABASE biblioteki;
```

W tym momencie w naszym środowisku zostanie utworzona pusta baza danych o nazwie biblioteki.

Pobranie pliku TERC:

Ze strony: <https://eteryt.stat.gov.pl> należy pobrać aktualny plik TERC (krajowy rejestr podziału terytorialnego kraju) i umieścić go w folderze razem z plikami .py.

Konfiguracja:

Konieczne jest teraz uzyskanie identyfikatora klienta BDL. Należy dokonać bezpłatnej rejestracji pod adresem:

<https://bdl.stat.gov.pl/bdl/rejestracja>

Uzyskany identyfikator należy umieścić w pliku konfiguracyjnym.

Następnym krokiem jest uzupełnienie pliku konfiguracyjnego config.ini

```
[database]
host = adres hosta
port = numer portu
dbname = nazwa bazy danych
user = nazwa użytkownika
password = hasło

[api]
client_id = identyfikator klienta BDL

[paths]
data_dir = ścieżka do folderu
terc_filename = nazwa pliku TERC
```

Uruchomienie pipeline:

W celu uruchomienia przygotowanego pipeline należy wywołać plik main_parquet.py. By to zrobić należy otworzyć terminal w lokalizacji, w której znajdują się pliki projektu i wykonać komendę:

```
python main_parquet.py
```

To zainicjuje połączenie z API, pobieranie danych i finalnie zapisanie danych do bazy „biblioteki”.

Praca z danymi w PowerBI:

By móc rozpocząć pracę z przygotowanymi danymi należy uruchomić plik raport.pbix za pomocą narzędzie PowerBI, a następnie wybrać przycisk odśwież, co zainicjuje aktualizację danych do tych, które zostały przed chwilą pobrane do bazy danych. Konieczna będzie aktualizacja danych logowania do bazy danych na zgodne z podanymi wcześniej w pliku config.ini.