



AKADEMIAWIT
w WARSZAWIE

**WYDZIAŁ TECHNOLOGII
INFORMATYCZNYCH I ZARZĄDZANIA**

KIERUNEK INFORMATYCZNE TECHNIKI ZARZĄDZANIA

PRACA DYPLOMOWA INŻYNIERSKA

Dawid Buca

**Projekt i analiza systemu danych bibliotecznych
na podstawie danych GUS z lat 1999–2024
z wykorzystaniem SQL, Pythona i Power BI**

Promotor pracy:

Mgr inż. Maria Ocet

WARSZAWA, rok akademicki 2025/2026



OŚWIADCZENIE AUTORA PRACY

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami prawa, w szczególności z ustawą z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (Dz. U. z 1994 r. Nr 24, poz. 83 – tekst pierwotny i Dz. U. z 2000 r. Nr 80, poz. 904 – tekst jednolity, z późn. zm.). Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w szkole wyższej. Oświadczam także, że wersja pracy składana w dziekanacie, pliki elektroniczne pracy zawierają identyczną treść. Oświadczam również, że wszystkie narzędzia informatyczne zastosowane do wykonania niniejszej pracy wykorzystałem zgodnie z obowiązującymi przepisami prawa w zakresie ochrony własności intelektualnej i przemysłowej. Wyrażam zgodę na przetwarzanie następujących danych osobowych: imiona, nazwisko, nr albumu, temat pracy dyplomowej oraz oceny na dyplomie, ukończony kierunek oraz rok, system i rodzaj studiów, adres do korespondencji (w tym e-mail i telefon kontaktowy) dla celów badania losu absolwenta zgodnie z Rozporządzeniem Parlamentu Europejskiego i Rady Unii Europejskiej 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych oraz uchylenia dyrektywy 95/46/WE (RODO).

Wyrażam zgodę na publikację pracy.

Wyrażam zgodę na przetwarzanie następujących danych osobowych: imiona, nazwisko, nr albumu, ukończony kierunek oraz rok, system i rodzaj studiów, adres do korespondencji (w tym e-mail i telefon kontaktowy) dla celów promocji uczelni zgodnie z Rozporządzeniem Parlamentu Europejskiego i Rady Unii Europejskiej 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych oraz uchylenia dyrektywy 95/46/WE (RODO).

Wyrażam zgodę na przetwarzanie następujących danych osobowych: tematu pracy dyplomowej oraz oceny na dyplomie dla celów promocji uczelni zgodnie z Rozporządzeniem Parlamentu Europejskiego i Rady Unii Europejskiej 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych oraz uchylenia dyrektywy 95/46/WE (RODO).

Wyrażam zgodę na przetwarzanie następujących danych osobowych: aktualnego miejsca pracy, miejsca pracy po ukończeniu studiów oraz obecnie zajmowanego stanowiska dla celów promocji uczelni zgodnie z Rozporządzeniem Parlamentu Europejskiego i Rady Unii Europejskiej 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych oraz uchylenia dyrektywy 95/46/WE (RODO).

Wyrażam zgodę na przysyłanie mi informacji o ofertach uczelni i ankiet dla celów promocji uczelni zgodnie z Rozporządzeniem Parlamentu Europejskiego i Rady Unii Europejskiej 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych oraz uchylenia dyrektywy 95/46/WE (RODO).

Wyrażam zgodę na przetwarzanie następujących danych osobowych: imiona, nazwisko, nr albumu, ukończony kierunek, specjalność oraz rok, system i rodzaj studiów, wynik ukończenia, miejsce urodzenia w celu wydrukowania dyplomu na zlecenie uczelni przez drukarnię ZPW Bogucin k/Poznania z siedzibą w Kobylnicy, ul. Gnieźnieńska 127 zgodnie z Rozporządzeniem Parlamentu Europejskiego i Rady Unii Europejskiej 2016/679 z dnia 27 kwietnia 2016 r. w sprawie ochrony osób fizycznych w związku z przetwarzaniem danych osobowych i w sprawie swobodnego przepływu takich danych oraz uchylenia dyrektywy 95/46/WE (RODO).

28/01/2026

(data)

21507

(album)

Dawid Buca

(student)

.....
(podpis studenta)

SPIS TREŚCI

WSTĘP	9
1. CEL I ZAKRES PRACY ORAZ CHARAKTERYSTYKA PROJEKTOWANEGO SYSTEMU.....	10
1.1 Cel i przedmiot pracy.....	10
1.2 Zakres pracy	10
1.3 Przeznaczenie i zastosowanie projektowanego systemu	11
1.4 Charakterystyka użytkownika systemu	12
2. BIBLIOTEKI PUBLICZNE W GMINIE – KONTEKST ORGANIZACYJNY I INFORMACYJNY	13
2.1. Rola gminy jako organizatora biblioteki publicznej	13
2.2. Zakres danych wykorzystywanych w zarządzaniu bibliotekami publicznymi	13
2.3. Problemy w analizie danych bibliotecznych na poziomie gminy	14
3. ŹRÓDŁA DANYCH I ICH CHARAKTERYSTYKA	15
3.1. Bank Danych Lokalnych GUS jako źródło danych statystycznych	15
3.2. Zakres czasowy i przestrzenny analizowanych danych	15
3.3. Charakterystyka wskaźników bibliotecznych	16
3.4. Ograniczenia i jakość danych źródłowych	17
4. PROJEKT ARCHITEKTURY SYSTEMU	18
4.1 Założenia projektowe systemu	18
4.2 Architektura logiczna systemu	19
4.3 Podział systemu na warstwy funkcjonalne	21
4.4 Rola użytkownika końcowego w systemie	22
4.5 Wymagania systemowe	22
5. PROJEKT MODELU DANYCH	25
5.1. Teoretyczne modele architektury hurtowni danych.....	25
5.2 Koncepcja hurtowni danych.....	25
5.3 Projekt tabel pomocniczych i wymiar czasu.....	27
5.4 Projekt tabeli faktów	29
5.5 Relacje i integralność danych	32
5.6 Uzasadnienie przyjętego modelu danych	33
6. PROJEKT I IMPLEMENTACJA PROCESU ETL	35
6.1 Proces ekstrakcji danych z API GUS.....	35
6.2 Transformacja i standaryzacja danych	38
6.3 Konfiguracja i modularność systemu	42
6.4 Optymalizacja procesu ETL.....	45
6.5 Obsługa błędów i spójność danych	46
7. WARSTWA ANALITYCZNA SYSTEMU – POWER BI	51

7.1 Charakterystyka warstwy analitycznej systemu	51
7.2 Model analityczny danych	52
7.3. Zastosowane miary i wskaźniki.....	55
7.4. Analiza danych historycznych.....	57
7.5. Predykcja wybranych wskaźników	59
8. OCENA DZIAŁANIA SYSTEMU	63
8.1. Poprawność i kompletność przetwarzania danych	63
8.2. Użyteczność systemu z perspektywy użytkownika gminnego	65
8.3. Ograniczenia zaprojektowanego rozwiązania	68
9. PODSUMOWANIE I WNIOSKI.....	70
9.1. Osiągnięte cele pracy.....	70
9.2. Możliwości dalszego rozwoju systemu.....	71
BIBLIOGRAFIA	73
SPIS RZECZY	74
Spis rysunków	74
Spis tabel	75
WYKAZ WAŻNIEJSZYCH OZNACZEŃ UŻYTYCH W PRACY	76
WYKAZ ZAŁĄCZNIKÓW	77

WSTĘP

Dynamiczny rozwój narzędzi analitycznych oraz rosnąca dostępność danych publicznych sprawiają, że coraz większego znaczenia nabiera efektywne wykorzystanie informacji statystycznych w procesach decyzyjnych administracji publicznej. Jednym z obszarów, w którym analiza danych może stanowić istotne wsparcie dla jednostek samorządu terytorialnego, jest działalność bibliotek publicznych funkcjonujących na poziomie gmin. Biblioteki te pełnią ważną rolę w lokalnym systemie kultury, edukacji oraz dostępu do informacji.

Pomimo powszechnej dostępności danych statystycznych gromadzonych przez Główny Urząd Statystyczny w ramach Banku Danych Lokalnych, ich praktyczne wykorzystanie w urzędach gmin bywa ograniczone. Problemem jest rozproszenie informacji, brak spójnego modelu danych oraz konieczność pracochłonnego, ręcznego przetwarzania zestawień. Niniejsza praca stanowi odpowiedź na te wyzwania, koncentrując się na zaprojektowaniu systemu umożliwiającego automatyczne pozyskiwanie, przetwarzanie oraz analizę danych bibliotecznych z wykorzystaniem nowoczesnych narzędzi informatycznych.

Tezą pracy jest założenie, że budowa zautomatyzowanego potoku danych (ETL) opartego na języku Python oraz relacyjnej hurtowni danych w środowisku PostgreSQL, pozwala na stworzenie wydajnego i skalowalnego systemu analitycznego. Takie rozwiązanie inżynierskie minimalizuje ryzyko błędów ludzkich przy przetwarzaniu danych statystycznych oraz dostarcza użytkownikowi końcowemu wiarygodnych informacji o trendach czytelnich i demograficznych w ujęciu długookresowym.

Praca ma charakter projektowo-analityczny i została podzielona na dziewięć rozdziałów, które odzwierciedlają kolejne etapy cyklu życia projektu informatycznego:

- **Rozdział 1 i 2** definiują cel, zakres oraz kontekst merytoryczny i organizacyjny funkcjonowania bibliotek w strukturach gminy.
- **Rozdział 3** zawiera szczegółową charakterystykę źródeł danych, zakresu czasowego analiz oraz stosowanych wskaźników statystycznych.
- **Rozdział 4 i 5** poświęcone są projektowaniu architektury logicznej systemu, definicji wymagań oraz budowie relacyjnego modelu danych w bazie PostgreSQL.
- **Rozdział 6** opisuje implementację technologiczną procesu ETL w języku Python, mechanizmy obsługi błędów oraz optymalizację wydajnościową z wykorzystaniem formatu Parquet.
- **Rozdział 7** prezentuje warstwę analityczną wykonaną w Power BI, w tym definicje miar DAX oraz zastosowanie regresji liniowej do predykcji trendów czytelnich.
- **Rozdział 8** zawiera ocenę działania systemu pod kątem poprawności przetwarzania danych oraz użyteczności dla pracownika urzędu gminy.
- **Rozdział 9** stanowi podsumowanie zrealizowanych celów projektowych oraz wskazuje możliwości dalszego rozwoju systemu.

1. CEL I ZAKRES PRACY ORAZ CHARAKTERYSTYKA PROJEKTOWANEGO SYSTEMU

1.1 Cel i przedmiot pracy

Celem niniejszej pracy inżynierskiej jest zaprojektowanie oraz analiza systemu przetwarzania i analizy danych bibliotecznych, przeznaczonego do wykorzystania na poziomie gminy. System ma wspierać analizę działalności bibliotek publicznych w oparciu o dane statystyczne pochodzące z Banku Danych Lokalnych Głównego Urzędu Statystycznego.

Przedmiotem pracy jest projekt rozwiązania informatycznego umożliwiającego automatyczne pozyskiwanie, integrację oraz analizę danych opisujących funkcjonowanie bibliotek publicznych. Analizie poddane zostały w szczególności dane dotyczące liczby czytelników, liczby wypożyczeń, wielkości księgozbioru, liczby placówek bibliotecznych oraz dane demograficzne, wykorzystywane do budowy wskaźników względnych. Projekt koncentruje się na warstwie analitycznej systemu, umożliwiającej interpretację danych historycznych oraz obserwację zmian zachodzących w czasie.

1.2 Zakres pracy

Zakres pracy obejmuje zaprojektowanie kompletnego procesu analitycznego, począwszy od pozyskania danych źródłowych, poprzez ich przetwarzanie i standaryzację, aż po przygotowanie warstwy analitycznej umożliwiającej wizualizację i interpretację wyników.

W ramach pracy zrealizowano proces ETL (Extract, Transform, Load) z wykorzystaniem języka Python oraz relacyjnej bazy danych PostgreSQL. Dane pobierane są automatycznie z interfejsu API Banku Danych Lokalnych GUS, a następnie poddawane transformacji i ładowane do zaprojektowanego modelu danych w postaci hurtowni danych. Na podstawie przygotowanego modelu wykonano analizę danych historycznych oraz predykcję wybranych wskaźników z wykorzystaniem narzędzia Power BI.

Zakres czasowy analiz obejmuje dane z lat 1999–2024, co umożliwia obserwację długookresowych trendów w działalności bibliotek publicznych. Praca ma charakter projektowo-analityczny i koncentruje się na przygotowaniu rozwiązania możliwego do wykorzystania w praktyce administracji samorządowej.

1.3 Przeznaczenie i zastosowanie projektowanego systemu

Projektowany system przeznaczony jest do wspierania pracowników urzędu gminy w bieżącej oraz okresowej analizie danych dotyczących działalności bibliotek publicznych. Jego podstawowym zadaniem jest umożliwienie łatwego dostępu do uporządkowanych danych statystycznych oraz ich interpretacji bez konieczności ręcznego przetwarzania zestawień pochodzących z różnych źródeł.

System umożliwia analizę kluczowych wskaźników opisujących funkcjonowanie bibliotek publicznych, takich jak liczba czytelników, liczba wypożyczeń, wielkość księgozbioru oraz liczba placówek bibliotecznych. Dane te mogą być analizowane w ujęciu wieloletnim, co pozwala na obserwację zmian zachodzących w czasie oraz identyfikację długookresowych trendów w poziomie czytelnictwa i dostępności usług bibliotecznych.

Istotnym zastosowaniem systemu jest możliwość porównywania wyników pomiędzy jednostkami terytorialnymi, zarówno w obrębie jednej gminy na przestrzeni lat, jak i pomiędzy różnymi gminami. Dzięki wykorzystaniu danych demograficznych system umożliwia prezentację wskaźników względnych, co pozwala na bardziej obiektywną ocenę sytuacji niezależnie od wielkości populacji danej jednostki.

Projektowane rozwiązanie może być wykorzystywane jako narzędzie wspierające przygotowywanie analiz, zestawień oraz materiałów informacyjnych na potrzeby wewnętrzne urzędu gminy. Może ono również stanowić wsparcie w procesach planistycznych, takich jak ocena skutków podejmowanych działań, identyfikacja obszarów wymagających interwencji lub monitorowanie efektów zmian organizacyjnych w sieci bibliotek publicznych.

System nie jest narzędziem decyzyjnym w sensie formalnym, lecz pełni rolę wsparcia analitycznego, dostarczając rzetelnych i czytelnych informacji opartych na danych historycznych. Jego celem jest ułatwienie pracy użytkownika końcowego poprzez skrócenie czasu potrzebnego na przygotowanie analiz oraz ograniczenie ryzyka błędów wynikających z ręcznego przetwarzania danych.

1.4 Charakterystyka użytkownika systemu

Użytkownikiem projektowanego systemu jest pracownik urzędu gminy odpowiedzialny za analizę danych wykorzystywanych w procesach planistycznych, sprawozdawczych oraz decyzyjnych związanych z działalnością bibliotek publicznych. W praktyce są to osoby zatrudnione w wydziałach kultury, edukacji lub rozwoju gminy, które w swojej pracy korzystają z danych statystycznych.

Użytkownik systemu nie posiada zaawansowanych kompetencji informatycznych ani programistycznych, jednak regularnie pracuje z danymi liczbowymi oraz zestawieniami statystycznymi. Z tego względu projektowane rozwiązanie zostało zaprojektowane w taki sposób, aby umożliwiać analizę danych bez konieczności ingerencji w warstwę techniczną systemu. Głównym narzędziem pracy użytkownika jest warstwa wizualizacyjno-analityczna, umożliwiająca interaktywną eksplorację danych.

2. BIBLIOTEKI PUBLICZNE W GMINIE – KONTEKST ORGANIZACYJNY I INFORMACYJNY

2.1. Rola gminy jako organizatora biblioteki publicznej

Gmina jako jednostka samorządu terytorialnego pełni rolę organizatora biblioteki publicznej działającej na jej terenie. Do zadań gminy należy zapewnienie warunków organizacyjnych i funkcjonowania biblioteki, w tym utrzymanie infrastruktury, nadzór nad działalnością instytucji oraz realizacja zadań związanych z upowszechnianiem czytelnictwa i dostępu do kultury.

W praktyce oznacza to, że pracownicy urzędu gminy są zobowiązani do monitorowania działalności biblioteki publicznej oraz oceny jej funkcjonowania w dłuższym horyzoncie czasowym. Analiza danych statystycznych stanowi podstawę do przygotowywania sprawozdań, informacji dla organów gminy oraz materiałów wykorzystywanych w procesach planistycznych. Rzetelna ocena działalności biblioteki wymaga dostępu do danych historycznych oraz możliwości ich porównywania w czasie i pomiędzy jednostkami terytorialnymi.

Z punktu widzenia gminy istotne jest nie tylko bieżące monitorowanie działalności biblioteki, lecz także identyfikowanie trendów i zmian zachodzących w obszarze czytelnictwa. Dane statystyczne umożliwiają ocenę skutków podejmowanych działań oraz stanowią podstawę do formułowania wniosków dotyczących dalszego rozwoju bibliotek publicznych.

2.2. Zakres danych wykorzystywanych w zarządzaniu bibliotekami publicznymi

Zarządzanie bibliotekami publicznymi na poziomie gminy opiera się na analizie danych statystycznych opisujących ich działalność oraz skalę korzystania z usług bibliotecznych przez mieszkańców. Wśród najczęściej wykorzystywanych danych znajdują się informacje dotyczące liczby czytelników, liczby wypożyczeń, wielkości księgozbioru oraz liczby placówek bibliotecznych funkcjonujących na terenie gminy.

Istotnym uzupełnieniem danych bibliotecznych są dane demograficzne, w szczególności liczba mieszkańców gminy. Umożliwiają one przeliczanie wartości bezwzględnych na wskaźniki

względne, co pozwala na bardziej obiektywną ocenę poziomu czytelnictwa oraz porównywanie wyników pomiędzy gminami o różnej wielkości populacji.

Dane wykorzystywane w analizach mają zazwyczaj charakter historyczny i obejmują wieloletnie szeregi czasowe. Dzięki temu możliwe jest obserwowanie zmian zachodzących w czasie oraz identyfikowanie długoterminowych trendów w działalności bibliotek publicznych. W praktyce dane te pochodzą z oficjalnych źródeł statystycznych, w szczególności z Banku Danych Lokalnych Głównego Urzędu Statystycznego, który stanowi podstawowe źródło informacji wykorzystywanych w analizach prowadzonych przez administrację samorządową.

2.3. Problemy w analizie danych bibliotecznych na poziomie gminy

Pomimo dostępności danych statystycznych dotyczących działalności bibliotek publicznych, ich efektywne wykorzystanie na poziomie gminy napotyka na szereg trudności. Jednym z głównych problemów jest forma udostępniania danych, która często wymaga dodatkowego przetwarzania przed wykorzystaniem w analizach. Dane publikowane w Banku Danych Lokalnych (Rys. 2.1) mają charakter surowy i nie są bezpośrednio przystosowane do pracy analitycznej użytkownika urzędowego.

	biblioteki i filie	księgozbiór	czytelnicy w ciągu roku
Jednostka terytorialna ▲	2023	2023	2023
	[ob.]	[wol.]	[osoba]
Kłodzko (1)	2	91 611	2 608

Rysunek 2.1: Wybrane wskaźniki dla gminy Kłodzko na Portalu GUS BDL.

Kolejnym problemem jest brak spójnego modelu danych, który umożliwiałby łatwe łączenie informacji bibliotecznych z danymi demograficznymi oraz analizę w ujęciu wieloletnim. Ręczne przygotowywanie zestawień i raportów jest czasochłonne oraz podatne na błędy, szczególnie w przypadku większych zakresów czasowych lub porównań pomiędzy wieloma jednostkami terytorialnymi. Dodatkowym utrudnieniem jest ograniczona dostępność narzędzi analitycznych przystosowanych do potrzeb pracownika urzędu gminy. Brak jednolitego środowiska analitycznego utrudnia systematyczną analizę danych oraz ogranicza możliwość szybkiego reagowania na zmiany zachodzące w działalności bibliotek publicznych. W efekcie potencjał danych statystycznych nie jest w pełni wykorzystywany w procesach decyzyjnych realizowanych na poziomie gminy.

3. ŹRÓDŁA DANYCH I ICH CHARAKTERYSTYKA

3.1. Bank Danych Lokalnych GUS jako źródło danych statystycznych

Podstawowym źródłem danych wykorzystanych w niniejszej pracy jest Bank Danych Lokalnych Głównego Urzędu Statystycznego. Bank Danych Lokalnych jest oficjalnym systemem udostępniania danych statystycznych dotyczących sytuacji społecznej, demograficznej i infrastrukturalnej jednostek terytorialnych w Polsce. Dane zgromadzone w BDL są powszechnie wykorzystywane przez administrację publiczną, w tym przez jednostki samorządu terytorialnego, jako podstawa do analiz, sprawozdań oraz dokumentów planistycznych.

Istotną cechą Banku Danych Lokalnych jest możliwość dostępu do danych zarówno w postaci zestawień tabelarycznych, jak i za pośrednictwem publicznego interfejsu programistycznego API. W ramach niniejszego projektu wykorzystano interfejs API BDL, który umożliwia automatyczne pobieranie danych w ustrukturyzowanej formie. Takie rozwiązanie pozwala na systematyczne pozyskiwanie danych oraz ogranicza konieczność ręcznego przetwarzania plików źródłowych, co ma istotne znaczenie z punktu widzenia projektowanego systemu analitycznego.

Dane pobierane z BDL obejmują wybrane wskaźniki opisujące działalność bibliotek publicznych oraz dane demograficzne niezbędne do interpretacji wyników analiz. Wykorzystanie oficjalnego źródła danych statystycznych zapewnia ich porównywalność w skali kraju oraz spójność w ujęciu wieloletnim, co jest szczególnie istotne przy analizie trendów zachodzących na poziomie gminy.

3.2. Zakres czasowy i przestrzenny analizowanych danych


Dane wykorzystane w pracy obejmują wieloletni zakres czasowy, co umożliwia analizę zmian zachodzących w działalności bibliotek publicznych w perspektywie długookresowej. Zastosowanie danych historycznych pozwala na obserwację kierunków zmian, a nie jedynie porównywanie pojedynczych lat, które mogłoby prowadzić do błędnych lub niepełnych wniosków. Taki zakres danych jest szczególnie istotny w kontekście pracy urzędu gminy, gdzie decyzje podejmowane są z uwzględnieniem skutków widocznych w dłuższym okresie.

Zakres przestrzenny danych obejmuje jednostki samorządu terytorialnego na poziomie gmin, co odpowiada rzeczywistemu zakresowi kompetencji pracownika urzędu gminy. Każda jednostka terytorialna jest jednoznacznie identyfikowana przy użyciu kodów TERYT, które stanowią oficjalny system identyfikacji podziału administracyjnego kraju. Wykorzystanie kodów TERYT umożliwia precyzyjne łączenie danych pochodzących z różnych zbiorów oraz zapewnia spójność analiz nawet w przypadku występowania różnic w nazewnictwie jednostek.

Połączenie zakresu czasowego i przestrzennego danych umożliwia prowadzenie analiz zarówno w ujęciu lokalnym, jak i porównawczym. Pracownik urzędu gminy może analizować zmiany zachodzące w obrębie jednej gminy na przestrzeni lat, a jednocześnie odnosić je do sytuacji w innych gminach. Takie podejście pozwala na lepsze zrozumienie pozycji danej gminy na tle innych jednostek oraz identyfikację istotnych różnic i podobieństw.

3.3. Charakterystyka wskaźników bibliotecznych

Wskaźniki wykorzystane w projekcie zostały dobrane w taki sposób, aby w możliwie prosty i jednoznaczny sposób opisywały funkcjonowanie bibliotek publicznych na poziomie gminy. Podstawowe wskaźniki obejmują liczbę czytelników (Rys. 3.1) oraz liczbę wypożyczeń, które bezpośrednio odzwierciedlają poziom korzystania z usług bibliotecznych przez mieszkańców. Analiza tych danych pozwala na ocenę zmian zainteresowania ofertą biblioteczną w czasie.



Rysunek 3.1: Wykres przedstawiający liczbę czytelników na 1 tys. mieszkańców w poszczególnych latach.

Kolejną grupę wskaźników stanowią dane opisujące infrastrukturę biblioteczną, w szczególności wielkość księgozbioru oraz liczbę placówek bibliotecznych. Wskaźniki te umożliwiają ocenę dostępności zasobów bibliotecznych oraz zmian zachodzących w strukturze sieci bibliotek na terenie gminy. Ich analiza w ujęciu wieloletnim pozwala na identyfikację procesów rozwojowych lub ograniczających działalność bibliotek.

Istotnym uzupełnieniem danych bibliotecznych są dane demograficzne, w szczególności liczba mieszkańców gminy. Zastosowanie danych demograficznych umożliwia przeliczanie wartości bezwzględnych na wskaźniki względne, co ma kluczowe znaczenie przy porównywaniu gmin o różnej liczbie ludności. Dzięki temu analiza nie ogranicza się do prostych wartości liczbowych, lecz pozwala na bardziej obiektywną ocenę poziomu czytelnictwa oraz dostępności usług bibliotecznych.

Dobór wskaźników został dokonany z uwzględnieniem ich dostępności w Banku Danych Lokalnych oraz ich przydatności z punktu widzenia użytkownika końcowego systemu. W projekcie celowo pominięto wskaźniki finansowe, takie jak wydatki na biblioteki publiczne, koncentrując się na danych opisujących aktywność czytelnictwa oraz infrastrukturę biblioteczną, które stanowią podstawę dalszych analiz.

3.4. Ograniczenia i jakość danych źródłowych

Dane wykorzystane w niniejszej pracy pochodzą z Banku Danych Lokalnych Głównego Urzędu Statystycznego i stanowią oficjalne dane statystyczne publikowane przez instytucję państwową. Z tego względu przyjęto je jako wiarygodne źródło informacji do analizy działalności bibliotek publicznych na poziomie gminy.

Jednocześnie należy mieć na uwadze, że dane statystyczne o charakterze publicznym mogą w niektórych przypadkach zawierać braki dla wybranych lat lub jednostek terytorialnych. Braki te nie wynikają z błędów danych, lecz są konsekwencją specyfiki sprawozdawczości statystycznej, w której kompletność danych może się różnić w zależności od okresu lub zakresu raportowania.

Z tego względu w analizach przyjęto podejście polegające na koncentracji na długookresowych trendach oraz kierunkach zmian zachodzących w działalności bibliotek publicznych, a nie na interpretacji pojedynczych wartości liczbowych. Takie podejście pozwala na bardziej stabilną i wiarygodną interpretację wyników, szczególnie w analizach obejmujących wieloletni zakres czasowy. Jakość danych źródłowych została uwzględniona na etapie projektowania systemu analitycznego poprzez możliwość filtrowania danych oraz analizę wyłącznie dostępnych obserwacji. Zaprojektowane rozwiązanie nie modyfikuje danych źródłowych, a jego celem jest umożliwienie ich uporządkowanej prezentacji oraz analizy w ramach dostępnego zakresu informacyjnego.

4. PROJEKT ARCHITEKTURY SYSTEMU

4.1 Założenia projektowe systemu

System został zaprojektowany jako system analityczny służący do przetwarzania oraz analizy danych statystycznych dotyczących działalności bibliotek publicznych w Polsce. System bazuje na danych historycznych udostępnianych przez Bank Danych Lokalnych Głównego Urzędu Statystycznego i nie realizuje funkcji operacyjnych ani transakcyjnych związanych z bieżącą obsługą bibliotek. Jego zadaniem jest integracja danych, umożliwienie analizy zmian w czasie oraz wspomaganie interpretacji długookresowych trendów.

Podstawowym założeniem projektowym było zapewnienie automatycznego i powtarzalnego procesu przetwarzania danych. System został zaprojektowany w taki sposób, aby proces pozyskiwania danych z API GUS, ich transformacja oraz zapis do bazy danych mogły być realizowane cyklicznie, bez konieczności ręcznej ingerencji w kod źródłowy. Zastosowanie otwartego zakresu lat przy pobieraniu danych pozwala na automatyczne uwzględnianie nowych danych publikowanych przez GUS w kolejnych latach.

Kolejnym istotnym założeniem była modularność rozwiązania. Poszczególne etapy przetwarzania danych zostały rozdzielone na niezależne komponenty odpowiedzialne za pozyskiwanie danych, ich transformację oraz składowanie. Takie podejście zwiększa czytelność systemu, ułatwia jego utrzymanie oraz umożliwia wprowadzanie zmian lub optymalizacji w jednym obszarze bez wpływu na pozostałe elementy architektury.

System został zaprojektowany w oparciu o relacyjną bazę danych pełniącą rolę warstwy składowania danych analitycznych. Centralnym elementem jest tabela faktów zawierająca miary w układzie (TERYT, rok), uzupełniona o wymiar czasu oraz tabele techniczne wspierające proces ETL (staging, mapowanie identyfikatorów i walidacja kluczy).

Istotnym założeniem projektowym było również zapewnienie odporności systemu na błędy oraz spójności przetwarzanych danych. Proces ETL został zaprojektowany w taki sposób, aby w przypadku wystąpienia błędów możliwe było bezpieczne przerwanie przetwarzania i uniknięcie zapisu niekompletnych danych.

System został zaprojektowany z myślą o dalszej analizie danych w warstwie analitycznej. Dane zgromadzone w hurtowni stanowią bezpośrednie źródło dla narzędzi analitycznych, w których realizowana jest wizualizacja danych oraz obliczenia dodatkowych wskaźników i prognoz. Dzięki temu rozwiązanie umożliwia nie tylko analizę danych historycznych, lecz również ich wykorzystanie do prostych analiz predykcyjnych.

4.2 Architektura logiczna systemu

Architektura logiczna zaprojektowanego systemu została oparta na podejściu charakterystycznym dla systemów analitycznych oraz hurtowni danych. Jej głównym celem jest zapewnienie jednoznacznego i uporządkowanego przepływu danych od źródeł zewnętrznych do warstwy analitycznej, przy jednoczesnym rozdzieleniu odpowiedzialności pomiędzy poszczególne elementy systemu.

Proces przetwarzania danych rozpoczyna się w warstwie pozyskiwania danych, która odpowiada za komunikację z API Banku Danych Lokalnych GUS. Na tym etapie dane pobierane są w postaci surowej, zgodnie z określonym zakresem czasowym oraz poziomem agregacji jednostek terytorialnych. Mechanizmy paginacji oraz obsługi błędów połączeń zapewniają kompletność pobieranych danych oraz odporność procesu na problemy komunikacyjne.

Pobrane dane zapisywane są następnie w postaci plików pośrednich, które stanowią punkt przejściowy pomiędzy warstwą pozyskiwania a warstwą przetwarzania. Takie rozwiązanie pozwala na oddzielenie procesu pobierania danych od ich dalszego przetwarzania, co ułatwia testowanie, diagnostykę błędów oraz ewentualną optymalizację formatu danych.


Kolejnym elementem architektury logicznej jest warstwa przetwarzania danych, w której realizowany jest proces ETL. Dane z plików pośrednich ładowane są do warstwy staging w relacyjnej bazie danych, gdzie podlegają czyszczeniu, standaryzacji oraz integracji. Na tym etapie wykonywane jest m.in. mapowanie identyfikatorów jednostek administracyjnych oraz ujednolicenie danych pochodzących z różnych źródeł statystycznych.

Centralnym elementem architektury jest relacyjna baza danych pełniąca rolę hurtowni danych. Dane końcowe zapisywane są w tabeli faktów oraz w tabeli wymiaru czasu. Dodatkowo

wykorzystywane są tabele techniczne procesu ETL (staging i walidacja TERYT), natomiast hierarchia podziału administracyjnego została odwzorowana w warstwie prezentacji (Power BI) na podstawie pliku TERC. Taki model danych umożliwia efektywne przechowywanie danych historycznych oraz ich analizę w różnych przekrojach, takich jak czas czy jednostka terytorialna.

Ostatnim elementem architektury logicznej jest warstwa analityczna, która wykorzystuje dane zgromadzone w hurtowni do tworzenia wizualizacji, wskaźników oraz analiz trendów. Warstwa ta nie ingeruje w strukturę ani zawartość bazy danych, a jedynie odczytuje przygotowane wcześniej dane, zapewniając użytkownikowi końcowemu dostęp do wyników analiz w czytelnej i przystępnej formie.

Przyjęta architektura logiczna (Rys. 4.1) zapewnia spójność przetwarzanych danych, przejrzysty podział odpowiedzialności pomiędzy komponenty systemu oraz możliwość dalszej rozbudowy rozwiązania, np. poprzez dodanie nowych źródeł danych lub rozszerzenie warstwy analitycznej o dodatkowe metody analizy.



Rysunek 4.1 Architektura logiczna systemu

4.3 Podział systemu na warstwy funkcjonalne

Podział systemu na warstwy funkcjonalne został zastosowany w celu uporządkowania odpowiedzialności poszczególnych elementów rozwiązania oraz ograniczenia wzajemnych zależności pomiędzy nimi. Takie podejście jest charakterystyczne dla systemów analitycznych i umożliwia łatwiejsze utrzymanie oraz rozwój systemu w przyszłości.

Warstwa pozyskiwania danych odpowiada wyłącznie za komunikację z zewnętrznym źródłem danych i nie realizuje żadnych operacji analitycznych ani transformacji biznesowych. Dzięki temu zmiany w sposobie udostępniania danych przez API GUS nie wpływają bezpośrednio na strukturę bazy danych ani warstwę analityczną.

Warstwa przetwarzania danych realizuje operacje transformacyjne i integracyjne. Jej zadaniem jest przygotowanie danych w taki sposób, aby mogły zostać zapisane w spójnej strukturze hurtowni danych. Oddzielenie tej warstwy od pozostałych elementów systemu umożliwia kontrolę jakości danych oraz bezpieczne przetwarzanie danych w ramach transakcji.

Warstwa składowania danych pełni funkcję stabilnego repozytorium danych analitycznych. Dane zapisane w tej warstwie nie są modyfikowane przez użytkownika końcowego, co zapewnia ich spójność oraz umożliwia wykonywanie powtarzalnych analiz w oparciu o te same zbiory danych.

Warstwa analityczna odpowiada za prezentację danych oraz realizację obliczeń analitycznych na podstawie danych zgromadzonych w hurtowni. Oddzielenie tej warstwy od warstw wcześniejszych eliminuje ryzyko ingerencji w dane źródłowe oraz pozwala na swobodne rozwijanie raportów i wizualizacji bez wpływu na proces ETL.

Zastosowany podział na warstwy funkcjonalne umożliwia niezależny rozwój poszczególnych części systemu oraz zwiększa jego odporność na zmiany, zarówno po stronie źródeł danych, jak i narzędzi analitycznych.

4.4 Rola użytkownika końcowego w systemie

Użytkownik końcowy zaprojektowanego systemu pełni rolę odbiorcy oraz analityka danych. Jego zadaniem nie jest zarządzanie danymi ani kontrola procesów przetwarzania, lecz interpretacja wyników analiz przygotowanych w warstwie analitycznej systemu. Użytkownik nie posiada dostępu do warstwy pozyskiwania danych, przetwarzania ani do struktury bazy danych, co eliminuje ryzyko nieautoryzowanej modyfikacji danych.

Interakcja użytkownika z systemem odbywa się wyłącznie za pośrednictwem narzędzi analitycznych, które wykorzystują dane zgromadzone w hurtowni danych. Użytkownik ma możliwość przeglądania danych historycznych, porównywania wskaźników pomiędzy jednostkami terytorialnymi oraz analizy zmian wartości w czasie. System umożliwia filtrowanie i segmentację danych według wybranych kryteriów, takich jak rok czy jednostka administracyjna, bez konieczności ingerencji w dane źródłowe.

Rola użytkownika końcowego sprowadza się zatem do analizy i interpretacji wyników, a nie do obsługi technicznych aspektów systemu. Takie podejście pozwala oddzielić warstwę techniczną od warstwy decyzyjnej i sprawia, że system może być wykorzystywany przez osoby nieposiadające wiedzy programistycznej.

Przyjęty model użytkowania systemu sprzyja także powtarzalności analiz oraz porównywalności wyników w czasie. Użytkownik korzysta z jednolitego, spójnego zbioru danych, co umożliwia prowadzenie analiz opartych na tych samych założeniach i minimalizuje ryzyko błędnej interpretacji wyników wynikającej z niespójności danych.

4.5 Wymagania systemowe

Wymagania systemowe zaprojektowanego rozwiązania zostały opracowane na podstawie analizy celu pracy, przyjętych założeń projektowych oraz planowanego sposobu wykorzystania systemu przez użytkownika końcowego. W procesie ich definiowania uwzględniono zarówno potrzeby funkcjonalne związane z przetwarzaniem, integracją i analizą danych bibliotecznych, jak i wymagania нефunkcjonalne odnoszące się do jakości działania systemu, jego niezawodności, czytelności oraz możliwości dalszej rozbudowy. Wymagania funkcjonalne (Tabela 4.1) opisują zakres operacji realizowanych przez system na poszczególnych etapach

przetwarzania danych, natomiast wymagania niefunkcjonalne (Tabela 4.2) określają warunki, w jakich system powinien działać oraz cechy wpływające na jego użyteczność i stabilność. Takie rozdzielenie pozwala na jednoznaczne określenie zakresu odpowiedzialności systemu oraz stanowi punkt odniesienia do dalszych etapów projektowania, implementacji i oceny zaprojektowanego rozwiązania.

Wymagania funkcjonalne:

Tabela 4.1: Wymagania funkcjonalne

ID	Tytuł wymagania	Treść wymagania	Kryterium akceptacji
F-01	Pobranie danych z API GUS BDL	System musi pobierać dane statystyczne z API Banku Danych Lokalnych GUS dla wskazanych zmiennych (np. czytelnicy, wypożyczenia, księgozbiór, placówki, populacja) na poziomie jednostek (unit-level=6).	Dla każdej zdefiniowanej zmiennej system zapisuje rekordy zawierające: unit_id, unit_name, year, value (oraz teryt dla populacji).
F-02	Zakres czasowy pobierania danych	System musi pobierać dane w zakresie lat od 1999 do najnowszego dostępnego roku, bez konieczności zmiany kodu przy pojawieniu się nowych lat w API.	Uruchomienie po pojawieniu się nowego roku w BDL skutkuje zapisaniem nowych rekordów dla tego roku bez modyfikacji kodu.
F-03	Obsługa paginacji API	System musi obsługiwać paginację wyników API (pobieranie kolejnych stron na podstawie linku „next”).	Dla zmiennej o liczbie wyników > page-size, system pobiera komplet wyników (brak uciętych danych).
F-04	Zapis danych pośrednich do plików	System musi zapisywać pobrane dane w plikach pośrednich w katalogu roboczym (CSV lub Parquet), po jednym pliku na zmienną.	Po uruchomieniu powstaje komplet plików dla wszystkich zmiennych, a liczba rekordów w pliku > 0 (o ile API zwróci dane).
F-05	Wyznaczenie kodu TERYT	System musi nadawać kod TERYT jednostkom na podstawie unit_id (np. dla populacji) oraz uzupełniać brakujące TERYT w pozostałych źródłach poprzez mapowanie unit_id → TERYT.	Dla rekordów w staging teryt jest uzupełnione (niepuste) dla wszystkich źródeł, jeżeli dana jednostka występuje w mapowaniu.
F-06	Załadunek danych do warstwy staging	System musi ładować dane z plików pośrednich do tabeli staging (np. stg_miary), dodając metadane źródła (source).	W tabeli stg_miary znajdują się rekordy dla wszystkich źródeł z poprawnie ustawioną kolumną source.
F-07	Budowa modelu relacyjnego w bazie	System musi tworzyć (jeśli nie istnieją) tabele bazy danych dla warstwy składowania danych analitycznych, obejmujące tabelę faktów, wymiar czasu oraz tabele techniczne ETL (staging, mapowanie identyfikatorów i walidacja kodów TERYT).	Po uruchomieniu ETL w bazie istnieją tabele: stg_miary, map_unitid_teryt, stg_teryt, dim_year oraz fact_biblioteki, wraz z kluczami i relacjami zgodnymi z projektem.
F-08	Integracja danych w tabeli faktów	System musi konsolidować miary w tabeli faktów (np. fact_biblioteki) w układzie: (teryt, year) → wartości miar (populacja, czytelnicy, wypożyczenia, księgozbiór, placówki).	Dla przykładowej jednostki i roku w fact_biblioteki występuje dokładnie jeden rekord (unikalność po teryt+year).
F-09	Tryb przyrostowy ładowania danych	System musi umożliwiać tryb przyrostowy: czyszczenie tylko staging, dopisywanie nowych rekordów do tabeli faktów bez dublowania danych.	Ponowne uruchomienie ETL nie zwiększa liczby rekordów dla istniejących par (teryt, year).

F-10	Spójność transakcyjna ETL	System musi wykonywać ETL w transakcji i w przypadku błędu wykonać rollback, aby uniknąć częściowo załadowanych danych.	Po wymuszeniu błędu w trakcie ETL dane w fact pozostają w stanie sprzed uruchomienia.
F-11	Udostępnienie danych do analizy w Power BI	System musi udostępniać dane z hurtowni do warstwy analitycznej (Power BI) w sposób umożliwiający filtrowanie po latach i jednostkach.	W Power BI możliwe jest filtrowanie po roku na podstawie dim_year oraz po jednostkach i hierarchii administracyjnej na podstawie tabel TERC (gminy/powiaty/województwa) powiązanych z fact_biblioteki po kodzie TERYT.
F-12	Predykcja trendu dla wybranej miary	System musi umożliwiać obliczenie prognozy (np. regresja liniowa) dla wybranego wskaźnika do określonego roku (np. 2030).	W warstwie analitycznej dostępna jest seria prognozy dla lat przyszłych i można ją pokazać na wykresie obok danych historycznych.

Wymagania niefunkcjonalne:

Tabela 4.2: Wymagania niefunkcjonalne

ID	Tytuł wymagania	Treść wymagania	Kryterium akceptacji
NF-01	Dostępność środowiska uruchomieniowego	System powinien działać w standardowym środowisku użytkownika (Python + PostgreSQL + Power BI) bez wymagań komercyjnych poza samym Power BI.	Projekt uruchamia się na czystym środowisku po instalacji zależności i konfiguracji pliku config.ini
NF-02	Konfigurowalność	Parametry połączenia do bazy i ścieżki plików muszą być odseparowane od kodu (plik konfiguracyjny).	Zmiana hosta/hasła/ścieżki nie wymaga edycji kodu, tylko config.ini.
NF-03	Odporność na błędy API	System powinien obsługiwać błędy zapytań API (timeout, brak internetu, błędy HTTP) poprzez ponowienia i kontrolowane przerwanie pobierania.	Przy symulacji braku internetu skrypt kończy pracę komunikatem i nie zawiesza się w nieskończoność.
NF-04	Odporność na błędy ETL	W przypadku błędu przetwarzania system ma pozostawić bazę w spójnym stanie (transakcja + rollback).	Po błędzie nie istnieją częściowo wstawione rekordy w fact dla bieżącego uruchomienia.
NF-05	Skalowalność czasowa	System powinien automatycznie obejmować nowe lata danych publikowane w BDL bez zmian w logice pobierania.	Po dodaniu nowego roku w BDL system pobiera i ładuje rekordy dla tego roku.
NF-06	Skalowalność zakresu miar	System powinien umożliwiać dodanie nowej miary (zmiennej BDL) przy minimalnej zmianie konfiguracji.	Dodanie zmiennej wymaga dopisania jej ID i nazwy pliku (bez przebudowy całego systemu).
NF-07	Przejrzystość logów	System powinien generować czytelne komunikaty o przebiegu ETL (etapy, liczby rekordów, błędy).	W logach widać rozpoczęcie i zakończenie etapów oraz komunikat o commit/rollback.
NF-08	Użyteczność warstwy analitycznej	Dashboard Power BI powinien umożliwiać analizę trendów i porównań między jednostkami oraz prezentować wyniki w sposób czytelny (KPI, wykresy, filtry).	Użytkownik jest w stanie wybrać i odczytać wartości kluczowe wskaźników bez dodatkowego przetwarzania danych.

5. PROJEKT MODELU DANYCH

5.1. Teoretyczne modele architektury hurtowni danych

W procesie projektowania systemów analitycznych kluczowym wyzwaniem jest wybór struktury, w jakiej dane będą przechowywane w bazie. W literaturze przedmiotu wyróżnia się dwa fundamentalne podejścia, które reprezentują odmienne filozofie pracy z informacją:

- **Podejście Billa Inmona:** Autor ten zakłada, że hurtownia powinna być centralnym i niezwykle uporządkowanym zbiorem danych dla całej instytucji. Dane są w tym modelu znormalizowane (często do tzw. trzeciej postaci normalnej), co w praktyce oznacza taki podział tabel, aby każda informacja była zapisana tylko raz. Eliminuje to ryzyko niespójności, ale sprawia, że baza składa się z bardzo dużej liczby powiązanych ze sobą tabel. Wyciąganie danych do raportów wymaga w tym przypadku tworzenia skomplikowanych zapytań łączących wiele elementów.
- **Podejście Ralpha Kimballa:** To podejście skupia się na konkretnych potrzebach analitycznych i szybkości dostarczania wyników. Dane organizowane są w tzw. schemat gwiazdy. W jego centrum znajduje się tabela faktów (zawierająca główne liczby, np. ilość wypożyczeń), a wokół niej proste tabele wymiarów (zawierające opisy, np. rok lub nazwę gminy). Jest to struktura znacznie bardziej intuicyjna dla narzędzi takich jak Power BI i pozwala na szybsze generowanie zestawień.

Wybór architektury opartej na koncepcji Ralpha Kimballa był podyktowany przede wszystkim potrzebą stworzenia narzędzia przyjaznego dla użytkownika końcowego oraz wydajnego analitycznie. Model ten, oparty na tzw. schemacie gwiazdy, idealnie współgra z narzędziem Power BI, pozwalając na szybkie przeliczanie wskaźników bez nadmiernego obciążania bazy danych. Dzięki temu pracownik urzędu gminy może sprawnie filtrować dane i generować raporty, co byłoby znacznie trudniejsze w przypadku bardziej skomplikowanych, rozproszonych struktur bazodanowych.

5.2 Koncepcja hurtowni danych

Projektowany system analityczny wykorzystuje relacyjną hurtownię danych jako centralny element gromadzenia i udostępniania danych statystycznych dotyczących działalności bibliotek publicznych. Hurtownia danych pełni rolę wspólnego repozytorium, w którym integrowane są

dane pochodzące z różnych zbiorów tematycznych udostępnianych przez Bank Danych Lokalnych GUS.

Podstawowym założeniem przyjętej koncepcji hurtowni danych jest oddzielenie danych surowych od danych wykorzystywanych w analizach. Dane pozyskiwane z zewnętrznego źródła nie są analizowane bezpośrednio, lecz przechodzą przez proces ETL, w którym są czyszczone, standaryzowane oraz integrowane. Dopiero po tym etapie trafiają do docelowych struktur hurtowni danych, przygotowanych z myślą o analizie wielowymiarowej.

Warstwa składowania została zaprojektowana w oparciu o tabelę faktów oraz wymiar czasu. Proces ETL wykorzystuje dodatkowe tabele techniczne (staging, mapowanie identyfikatorów oraz walidację kodów TERYT), które wspierają integrację i kontrolę jakości danych przed ich zapisem do tabeli faktów. Takie podejście umożliwia analizę danych w różnych przekrojach, w szczególności według czasu oraz jednostek terytorialnych, co jest zgodne z charakterem danych statystycznych publikowanych przez GUS.

Istotnym elementem koncepcji hurtowni jest zastosowanie warstwy pośredniej (staging), która pełni rolę bufora pomiędzy danymi źródłowymi a docelowymi tabelami analitycznymi. W warstwie tej gromadzone są dane w postaci zbliżonej do oryginalnej, co umożliwia ich weryfikację, uzupełnianie braków oraz konwersję typów danych przed zapisaniem do tabel wymiarów i tabeli faktów. Rozwiązanie to zwiększa odporność systemu na niespójności danych źródłowych oraz ułatwia kontrolę jakości danych.

Projekt hurtowni danych zakłada również jednoznaczną identyfikację jednostek terytorialnych przy użyciu kodu TERYT. Kod ten stanowi wspólny identyfikator wykorzystywany w procesie integracji danych oraz w relacjach pomiędzy tabelą faktów a wymiarami w warstwie składowania. Szczegółowa struktura podziału administracyjnego, obejmująca hierarchię gmina–powiat–województwo, została natomiast odwzorowana w warstwie prezentacji systemu.

Model danych hurtowni opisuje struktury utrzymywane w bazie PostgreSQL (warstwa składowania). W warstwie prezentacji (Power BI) zastosowano model semantyczny, w którym część wymiarów, w szczególności podział administracyjny, została zbudowana bezpośrednio na podstawie pliku TERC jako źródła danych referencyjnych.

5.3 Projekt tabel pomocniczych i wymiar czasu

Projekt modelu danych w warstwie składowania został podporządkowany realizacji procesu ETL oraz zapewnieniu spójności danych zapisywanych w tabeli faktów. W przeciwieństwie do klasycznego podejścia hurtownianego, w którym wszystkie wymiary przechowywane są w bazie danych, w niniejszym rozwiązaniu zastosowano ograniczony zestaw struktur pomocniczych oraz jeden wymiar analityczny – wymiar czasu. Pozostałe wymiary, w szczególności podział administracyjny, zostały przeniesione do warstwy prezentacji.

Wymiar czasu (dim_year):

Tabela dim_year pełni rolę jedyne go wymiaru analitycznego przechowywanego w bazie PostgreSQL. Zawiera ona listę lat występujących w danych źródłowych i stanowi punkt odniesienia dla analiz trendów czasowych. Wymiar ten jest automatycznie uzupełniany na podstawie danych znajdujących się w tabeli stagingowej, co eliminuje konieczność ręcznego zarządzania jego zawartością.

Relacja pomiędzy tabelą faktów a wymiarem czasu została zrealizowana za pomocą klucza obcego (year), co zapewnia integralność danych oraz umożliwia jednoznaczne filtrowanie i agregację wyników według lat w dalszych analizach.

Tabela stagingowa danych (stg_miary):

Tabela stg_miary (Rys. 5.1) stanowi warstwę pośrednią pomiędzy danymi źródłowymi a strukturami docelowymi hurtowni danych. Przechowywane są w niej dane w formacie zbliżonym do oryginalnego, bez wcześniejszej agregacji i normalizacji. Tabela ta zawiera m.in. identyfikator jednostki źródłowej, rok, wartość miary oraz informację o pochodzeniu danych.

	AZ unit_id	AZ unit_name	123 year	AZ value	AZ teryt	AZ source
87	011212001032	Drwinia	2,021	6.48	1201032	populacja
88	011212001032	Drwinia	2,022	6.47	1201032	populacja
89	011212001032	Drwinia	2,023	6.43	1201032	populacja
90	011212001032	Drwinia	2,024	6.35	1201032	populacja
91	011212001042	Lipnica Murowana	1,995	5.38	1201042	populacja
92	011212001042	Lipnica Murowana	1,996	5.39	1201042	populacja
93	011212001042	Lipnica Murowana	1,997	5.43	1201042	populacja
94	011212001042	Lipnica Murowana	1,998	5.45	1201042	populacja
95	011212001042	Lipnica Murowana	1,999	5.42	1201042	populacja
96	011212001042	Lipnica Murowana	2,000	5.43	1201042	populacja
97	011212001042	Lipnica Murowana	2,001	5.43	1201042	populacja
98	011212001042	Lipnica Murowana	2,002	5.44	1201042	populacja
99	011212001042	Lipnica Murowana	2,003	5.44	1201042	populacja
100	011212001042	Lipnica Murowana	2,004	5.47	1201042	populacja

Rysunek 5.1: Fragment tabeli stagingowej w bazie danych PostgreSQL.

Zastosowanie tabeli stagingowej umożliwia:

- weryfikację kompletności i poprawności danych,
- konwersję typów danych (np. wartości tekstowych na liczbowe),
- uzupełnianie brakujących identyfikatorów terytorialnych,
- integrację danych pochodzących z wielu zbiorów tematycznych.

Tabela stg_miary jest czyszczona przy każdym uruchomieniu procesu ETL i nie pełni funkcji analitycznej – jej rolą jest wyłącznie wsparcie procesu przetwarzania danych.

Mapowanie identyfikatorów (map_unitid_teryt):

Tabela map_unitid_teryt (Rys. 5.2) została zaprojektowana w celu powiązania identyfikatorów jednostek występujących w danych źródłowych Banku Danych Lokalnych z kodami TERYT. Mapowanie to budowane jest automatycznie na podstawie zbioru populacji, w którym kod TERYT występuje bezpośrednio. Dzięki zastosowaniu tej tabeli możliwe jest uzupełnienie brakujących kodów TERYT w pozostałych zbiorach danych, co zapewnia spójność klucza terytorialnego w całym procesie ETL i umożliwia późniejszą integrację danych w tabeli faktów.

	AZ unit_id	AZ teryt
1	011212001011	1201011
2	011212001022	1201022
3	011212001032	1201032
4	011212001042	1201042
5	011212001052	1201052
6	011212001063	1201063
7	011212001064	1201064
8	011212001065	1201065
9	011212001072	1201072
10	011212001082	1201082

Rysunek 5.2: Fragment tabeli map_unitid_teryt w bazie danych PostgreSQL.

Walidacja kodów terytorialnych (stg_teryt):

Tabela stg_teryt pełni funkcję technicznej tabeli referencyjnej wykorzystywanej do walidacji poprawności kodów TERYT. Zawiera ona wyłącznie listę poprawnych kodów terytorialnych, które występują jednocześnie w danych źródłowych oraz w pliku TERC.

Tabela ta nie jest wymiarem analitycznym i nie jest wykorzystywana w warstwie prezentacji. Jej zadaniem jest:

- odfiltrowanie rekordów z niepoprawnym lub nieznanym kodem TERYT,
- zapewnienie integralności referencyjnej poprzez klucz obcy w tabeli faktów,
- zwiększenie odporności systemu na niespójności danych źródłowych.

Podsumowanie roli tabel pomocniczych:

Zastosowany zestaw tabel pomocniczych pozwala na zachowanie prostoty modelu danych w warstwie składowania przy jednoczesnym zapewnieniu poprawności, spójności i jakości danych. Ograniczenie liczby wymiarów w bazie danych było świadomą decyzją projektową, wynikającą z faktu, że pełna hierarchia podziału administracyjnego jest wykorzystywana wyłącznie w warstwie prezentacji systemu. Takie podejście umożliwia efektywne przetwarzanie danych w procesie ETL oraz elastyczne modelowanie analiz w Power BI, bez nadmiernego rozbudowywania struktury relacyjnej hurtowni danych.

5.4 Projekt tabeli faktów

Centralnym elementem modelu danych w warstwie składowania jest tabela faktów fact_biblioteki, która przechowuje zagregowane dane statystyczne opisujące działalność bibliotek publicznych. Tabela ta stanowi podstawę dalszych analiz realizowanych w warstwie

prezentacji i została zaprojektowana w taki sposób, aby umożliwiać analizę danych w układzie czasowo-terytorialnym.

Każdy rekord w tabeli faktów reprezentuje zestaw miar dla konkretnej jednostki terytorialnej oraz danego roku. Przyjęcie układu, w którym jeden wiersz tabeli odpowiada danym dla konkretnej jednostki terytorialnej i jednego roku, umożliwia spójne porównywanie wyników pomiędzy jednostkami oraz analizę zmian zachodzących w czasie.

Klucze i identyfikacja rekordów:

Tabela fact_biblioteki posiada klucz główny złożony z dwóch atrybutów:

- teryt – kod jednostki terytorialnej,
- year – rok, którego dotyczą dane.

Zastosowanie klucza złożonego zapobiega duplikacji danych oraz umożliwia bezpieczne odświeżanie rekordów w przypadku ponownego uruchomienia procesu ETL. Dodatkowo tabela faktów zawiera klucze obce:

- klucz obcy year, wskazujący na tabelę dim_year, który zapewnia spójność danych czasowych,
- klucz obcy teryt, wskazujący na tabelę stg_teryt, wykorzystywaną do walidacji poprawności kodów TERYT przed zapisaniem danych faktów.

Takie rozwiązanie gwarantuje, że do tabeli faktów trafiają wyłącznie rekordy posiadające poprawne i znane identyfikatory.

Zakres przechowywanych miar:

Tabela fact_biblioteki (Rys. 5.3) przechowuje zestaw miar liczbowych opisujących różne aspekty funkcjonowania bibliotek publicznych. Do najważniejszych miar należą:

- liczba mieszkańców (populacja),
- liczba czytelników,
- liczba wypożyczeń,
- wielkość księgozbioru,
- liczba bibliotek i filii,

W tabeli faktów uwzględniono również kolumnę wydatki, jednak w warstwie prezentacji została ona ukryta, ponieważ nie jest wykorzystywana w ramach analiz realizowanych w niniejszej pracy. Jej obecność w modelu danych umożliwia jednak łatwe rozszerzenie zakresu analiz w przyszłości, bez konieczności modyfikacji struktury hurtowni danych.

	A2 teryt	123 year	123 populacja	123 czytelnicy	123 wypożyczenia	123 księgozbiór	123 biblioteki_i_filie	123 wydatki
1	2201063	2,016	19.75	2,137	79,211	63,152	4	661,500
2	1404022	2,011	12.21	1,488	20,825	67,689	6	320,000
3	0219072	2,019	17.31	809	23,609	23,651	4	281,178
4	2204062	2,021	10.68	986	27,392	26,920	1	475,000
5	0221063	2,006	7.5	1,319	27,613	36,158	3	134,000
6	2205062	2,016	10.24	1,267	31,978	22,377	2	300,000
7	2811032	2,007	6.11	703	12,433	27,946	3	105,884.29
8	0806013	2,024	6.08	1,063	21,137	24,647	1	109,500
9	0204032	2,017	4.99	591	7,483	42,877	2	168,000
10	1610023	2,004	14.58	2,399	38,117	76,628	8	128,066
11	3010073	2,014	8.44	929	30,819	14,663	1	180,000
12	0612012	2,023	6.29	396	7,771	14,139	2	171,720.42
13	2004053	2,013	6.38	832	15,993	35,329	2	265,587.84
14	2005092	2,020	3.29	256	4,143	21,225	3	208,600
15	2807063	2,012	13.1	1,498	26,231	24,099	3	189,500

Rysunek 5.3: Fragment tabeli faktów w bazie danych PostgreSQL.

Miary te pochodzą z różnych zbiorów tematycznych Banku Danych Lokalnych GUS i są integrowane w ramach procesu ETL do wspólnej struktury tabeli faktów. Przed zapisaniem danych do tabeli wykonywana jest konwersja typów danych oraz czyszczenie wartości (np. usuwanie znaków nieliczbowych, zamiana separatorów dziesiętnych), co zapewnia ich spójność i poprawność.

Dane zapisywane w tabeli faktów są agregowane na etapie ładowania z warstwy stagingowej. Proces ten polega na połączeniu danych po kodzie TERYT oraz roku i przypisaniu odpowiednich wartości do poszczególnych miar. W wyniku tego działania powstaje jeden rekord faktów dla każdej kombinacji jednostki terytorialnej i roku. Zastosowanie agregacji na etapie ETL pozwala uprościć model danych oraz ograniczyć konieczność wykonywania złożonych obliczeń po stronie warstwy analitycznej.

Obsługa aktualizacji danych i rola tabeli faktów:

Tabela fact_biblioteki została zaprojektowana z myślą o wielokrotnym uruchamianiu procesu ETL oraz pełni centralną rolę w całym systemie analitycznym. W przypadku próby wstawienia rekordu o istniejącym kluczu głównym (kod TERYT oraz rok) wykorzystywany jest mechanizm aktualizacji danych, który nadpisuje wartości miar nowymi danymi. Takie podejście umożliwia bezpieczne odświeżanie danych, uwzględnianie ewentualnych korekt danych historycznych po stronie źródła oraz zachowanie spójności danych bez konieczności ręcznego usuwania rekordów.

Tabela faktów stanowi jedyne źródło danych liczbowych wykorzystywanych w analizach i wizualizacjach w warstwie prezentacji. Dane zapisane w tej tabeli są podstawą do obliczania

wskaźników, porównań pomiędzy jednostkami terytorialnymi oraz analiz zmian w czasie. Świadome ograniczenie zakresu przechowywanych danych do zagregowanych miar pozwala zachować przejrzystość modelu danych oraz zapewnia dobrą wydajność zapytań analitycznych i raportów.

5.5 Relacje i integralność danych

Relacje pomiędzy tabelami w warstwie składowania danych zostały zaprojektowane w taki sposób, aby zapewnić spójność, poprawność oraz jednoznaczną identyfikację danych zapisywanych w tabeli faktów. Integralność danych realizowana jest na poziomie relacyjnej bazy danych PostgreSQL poprzez zastosowanie kluczy głównych oraz kluczy obcych.

Centralnym elementem relacji jest tabela `fact_biblioteki`, która posiada klucz główny złożony z kodu TERYT oraz roku. Taka konstrukcja uniemożliwia występowanie duplikatów dla tej samej jednostki terytorialnej w danym roku oraz pozwala na bezpieczne wielokrotne uruchamianie procesu ETL.

Integralność czasowa danych zapewniona jest poprzez klucz obcy `year`, który odwołuje się do tabeli `dim_year`. Rozwiązanie to gwarantuje, że każdy rekord w tabeli faktów odnosi się do poprawnie zdefiniowanego roku oraz umożliwia jednoznaczne filtrowanie i agregację danych w analizach czasowych.

Integralność terytorialna realizowana jest poprzez klucz obcy `teryt`, który wskazuje na tabelę `stg_teryt`. Tabela ta pełni funkcję technicznej tabeli walidacyjnej i zawiera wyłącznie listę poprawnych kodów TERYT. Dzięki temu do tabeli faktów trafiają jedynie rekordy z poprawnym i zweryfikowanym identyfikatorem jednostki terytorialnej, co chroni system przed błędami wynikającymi z niespójności danych źródłowych.

Tabela `stg_miary`, wykorzystywana jako warstwa stagingowa, nie jest objęta relacjami kluczy obcych. Jest to świadoma decyzja projektowa, wynikająca z jej roli jako bufora danych surowych. Umożliwia ona elastyczne przetwarzanie danych, ich czyszczenie oraz integrację przed zapisaniem do struktur docelowych bez ryzyka naruszenia integralności danych w tabeli faktów.

W warstwie prezentacji systemu relacje pomiędzy danymi realizowane są w modelu semantycznym Power BI. Dane faktów oraz wymiar czasu pochodzą z bazy PostgreSQL, natomiast hierarchia podziału administracyjnego (gmina–powiat–województwo) budowana jest na podstawie pliku TERC jako niezależnego źródła danych referencyjnych. Powiązanie tych danych odbywa się za pomocą wspólnego klucza TERYT, co zapewnia spójność analiz pomiędzy warstwą składowania a warstwą prezentacji.

Zastosowany podział odpowiedzialności pomiędzy bazą danych a warstwą analityczną pozwala zachować prostotę modelu relacyjnego przy jednoczesnym zapewnieniu elastyczności i czytelności analiz w Power BI.

5.6 Uzasadnienie przyjętego modelu danych

Przyjęty model danych został zaprojektowany w oparciu o rzeczywiste potrzeby analityczne systemu oraz charakter danych pozyskiwanych z Banku Danych Lokalnych GUS. Głównym celem projektu nie było stworzenie rozbudowanej hurtowni danych z pełnym zestawem wymiarów, lecz zapewnienie spójnego, czytelnego i łatwego w utrzymaniu modelu, który umożliwia efektywną analizę danych w warstwie prezentacji.

Centralną rolę w modelu pełni tabela faktów `fact_biblioteki`, zawierająca zagregowane miary opisujące działalność bibliotek publicznych w układzie jednostka terytorialna – rok. Takie rozwiązanie umożliwia analizę porównawczą pomiędzy jednostkami oraz obserwację zmian w czasie, przy jednoczesnym ograniczeniu liczby tabel i relacji w bazie danych. Uproszczenie struktury hurtowni przekłada się bezpośrednio na większą przejrzystość modelu oraz lepszą wydajność zapytań analitycznych.

Świadomą decyzją projektową było ograniczenie liczby wymiarów przechowywanych w bazie danych. W warstwie składowania utrzymano jedynie wymiar czasu (`dim_year`) oraz tabele techniczne wspierające proces ETL, takie jak staging danych, mapowanie identyfikatorów oraz walidacja kodów TERYT. Pozostałe wymiary, w szczególności hierarchia podziału administracyjnego, zostały przeniesione do warstwy prezentacji, gdzie są wykorzystywane bezpośrednio przez użytkownika końcowego.

Zastosowanie tabeli `stg_teryt` jako technicznego mechanizmu walidacji kodów TERYT pozwala na eliminację błędnych lub niejednoznacznych rekordów już na etapie ładowania danych. Rozwiązanie to zwiększa jakość danych zapisywanych w tabeli faktów, jednocześnie nie obciążając modelu danych dodatkowymi wymiarami, które nie są wykorzystywane w analizach.

Istotnym elementem uzasadnienia przyjętego modelu jest również rozdzielenie odpowiedzialności pomiędzy warstwę składowania a warstwę prezentacji. PostgreSQL pełni rolę stabilnego repozytorium danych faktów, natomiast Power BI odpowiada za model semantyczny, relacje użytkowe oraz prezentację danych w formie raportów i wizualizacji. Takie podejście umożliwia elastyczną rozbudowę systemu analitycznego bez konieczności ingerencji w strukturę bazy danych.

Model danych został zaprojektowany z myślą o dalszym rozwoju systemu. Przykładem takiego podejścia jest uwzględnienie w tabeli faktów kolumny wydatki, która obecnie nie jest wykorzystywana w analizach prezentowanych w niniejszej pracy, lecz może stanowić podstawę do rozszerzenia zakresu analiz o aspekty finansowe w przyszłości. Podobnie, zastosowany mechanizm aktualizacji danych w procesie ETL umożliwia łatwe odświeżanie danych oraz uwzględnianie korekt danych historycznych.

Podsumowując, przyjęty model danych stanowi kompromis pomiędzy prostotą struktury a funkcjonalnością analityczną. Zapewnia on spójność i poprawność danych, jest dostosowany do rzeczywistych potrzeb analitycznych oraz pozostawia przestrzeń do dalszej rozbudowy systemu w kolejnych etapach jego rozwoju.

6. PROJEKT I IMPLEMENTACJA PROCESU ETL

6.1 Proces ekstrakcji danych z API GUS

Proces ekstrakcji danych w projektowanym systemie realizowany jest z wykorzystaniem interfejsu API Banku Danych Lokalnych Głównego Urzędu Statystycznego (BDL). API to udostępnia dane statystyczne w sposób ustrukturyzowany, jednak ich pozyskanie wymaga nie tylko wskazania odpowiednich parametrów zapytania, lecz również wcześniejszego ustalenia identyfikatorów zmiennych odpowiadających analizowanym zagadnieniom.

W API BDL dane nie są pobierane bezpośrednio na podstawie nazw wskaźników, lecz za pomocą identyfikatorów zmiennych. Identyfikatory te są osadzone w rozbudowanej hierarchii tematycznej, co oznacza, że przed właściwą ekstrakcją danych konieczne było przeprowadzenie etapu eksploracyjnego, polegającego na wielokrotnych zapytaniach do API w celu dotarcia do właściwych tematów i podtematów. Proces ten polegał na pobraniu listy tematów nadrzędnych (Rys. 6.1), a następnie iteracyjnym „schodzeniu” w strukturze tematycznej przy użyciu identyfikatorów „rodziców”, aż do poziomu, na którym dostępne są konkretne zmienne statystyczne.

```
def get_tematy():  
    url = f"{URL}/subjects"  
    params = {"format": "json", "lang": "pl"}  
    r = requests.get(url=url, params=params, headers=HEADERS)  
    r.raise_for_status()  
    data = r.json()  
    return data
```

Rysunek 6.1: Przykład zapytania pobierającego listę tematów BDL.

Dopiero po zidentyfikowaniu odpowiednich tematów możliwe było pobranie listy zmiennych przypisanych do danego obszaru tematycznego i wybór tych, które odpowiadały zakresowi analiz prowadzonych w pracy (m.in. liczba czytelników, wypożyczenia, wielkość księgozbioru, liczba placówek bibliotecznych oraz wydatki). Etap identyfikacji zmiennych miał charakter przygotowawczy i był realizowany przy pomocy dedykowanych skryptów pomocniczych, które umożliwiały przeglądanie struktury BDL oraz weryfikację dostępnych wskaźników.

W wyniku wykonania funkcji pobierającej listę tematów z API BDL uzyskano zestaw tematów głównych dostępnych w systemie (Rys. 6.2). Przykładowe wyniki zapytania przedstawiono poniżej.

```
Lista tematów (subjects):  
K15 | CENY  
K43 | FINANSE PRZEDSIĘBIORSTW (DANE KWARTALNE)  
K27 | FINANSE PUBLICZNE  
K47 | FUNDUSZE UNIJNE (DANE PÓŁROCZNE)  
K11 | GOSPODARKA MIESZKANIOWA I KOMUNALNA  
K44 | GOSPODARKA SPOŁECZNA  
K16 | HANDEL I GASTRONOMIA  
K28 | INWESTYCJE I ŚRODKI TRWAŁE  
K23 | KULTURA  
K24 | KULTURA FIZYCZNA, SPORT I REKREACJA
```

Rysunek 6.2: Wynik pobrania listy tematów głównych z API Banku Danych Lokalnych GUS.

Na podstawie uzyskanej listy tematów do dalszej analizy wybrano temat „Kultura”, który zawiera podobszary związane z działalnością bibliotek publicznych. Ze względu na hierarchiczną strukturę API BDL, wybór tematu nadrzędnego nie umożliwia bezpośredniego pobrania zmiennych statystycznych. Konieczne było więc iteracyjne przechodzenie do kolejnych poziomów podtematów w ramach wybranego obszaru tematycznego, aż do osiągnięcia poziomu, na którym dostępne są konkretne zmienne wykorzystywane w dalszej części procesu ETL.

W celu eksploracji struktury podtematów wykorzystano zapytania do API BDL z użyciem identyfikatora tematu nadrzędnego parent-id (Rys. 6.3):

```
params = {"format": "json", "lang": "pl", "parent-id": "K23"}
```

Rysunek 6.3: Przykład definicji parametrów przy realizacji zapytania z użyciem parent-id.

Po dotarciu do najniższych poziomów struktury tematycznej, na których dostępne są dane szczegółowe, możliwe było określenie kontekstu zapytania do API BDL poprzez wskazanie identyfikatora konkretnego podtematu (Rys. 6.4). Identyfikator ten (subject-id) determinuje zakres zmiennych statystycznych dostępnych w danym obszarze tematycznym i stanowi podstawę do pobrania listy zmiennych wykorzystywanych w dalszej części procesu ekstrakcji danych.

```
params = {"format": "json", "lang": "pl", "subject-id": "P1691"}
```

Rysunek 6.4: Przykładowe określenie parametrów zapytania dla wybranego podtematu.

Po ustaleniu identyfikatorów zmiennych możliwe było uruchomienie właściwego procesu ekstrakcji danych. W tym celu przygotowano moduł odpowiedzialny za pobieranie obserwacji statystycznych dla wskazanych zmiennych w układzie jednostka terytorialna – rok. Zapytania do API konstruowane są w sposób parametryzowany i obejmują dane od roku 1999 do najnowszych dostępnych obserwacji (Rys. 6.5). Ze względu na potencjalnie dużą liczbę rekordów zastosowano mechanizm stronicowania wyników, który umożliwia pobieranie danych partiami i ich stopniowe przetwarzanie.

```
def get_variable_by_city_to_parquet(variable_id, filename_parquet: str):  
    url = f"{URL}/data/by-variable/{variable_id}"  
    params = {  
        "unit-level": 6,  
        "format": "json",  
        "year": "1999-",  
        "page-size": 100  
    }
```

Rysunek 6.5: Definicja parametrów dla zapytania do API BDL.

Istotnym elementem procesu ekstrakcji jest zapewnienie odporności na błędy komunikacji z API. W tym celu wywołania zapytań HTTP zostały opakowane w mechanizm ponawiania prób w przypadku nieudanej odpowiedzi serwera lub chwilowych problemów sieciowych (Rys. 6.6). Rozwiązanie to minimalizuje ryzyko przerwania całego procesu ekstrakcji z powodu pojedynczego błędu i zwiększa stabilność działania pipeline'u.

```
def safe_get(url, params, headers, retries=3, timeout=30):  
  
    for attempt in range(1, retries + 1):  
        try:  
            resp = requests.get(url, params=params, headers=headers, timeout=timeout)  
            resp.raise_for_status()  
            return resp  
        except RequestException as e:  
            print(f" Problem z zapytaniem (próba {attempt}/{retries}): {e}")  
            if attempt == retries:  
                print(" Maksymalna liczba prób wyczerpana - przerywam pobieranie tej zmiennej.")  
                return None
```

Rysunek 6.6: Mechanizm ponawiania prób w przypadku problemów połączenia z API.

W trakcie ekstrakcji dane zapisywane są w ujednoliconej strukturze obejmującej identyfikator jednostki (`unit_id`), nazwę jednostki, rok oraz wartość zmiennej. Po zakończeniu pobierania dane dla każdej zmiennej zapisywane są do osobnych plików w formacie Parquet. Zastosowanie tego formatu pozwala na efektywne przechowywanie danych oraz ich szybki odczyt w kolejnych etapach procesu ETL. Szczególną rolę w procesie ekstrakcji pełni zbiór danych dotyczących populacji, dla którego dodatkowo wyznaczany jest kod TERYT na podstawie identyfikatora jednostki BDL. Dane te wykorzystywane są w dalszym etapie jako źródło referencyjne do mapowania identyfikatorów jednostek na kody TERYT dla pozostałych zmiennych, które nie zawierają tego kodu bezpośrednio.

Proces ekstrakcji stanowi pierwszy etap całego pipeline'u ETL i jest uruchamiany przez moduł orkiestrujący. Jego poprawne wykonanie skutkuje utworzeniem zestawu plików wejściowych, które następnie poddawane są transformacji i ładowaniu do relacyjnej bazy danych PostgreSQL.

6.2 Transformacja i standaryzacja danych

Po zakończeniu etapu ekstrakcji dane dla poszczególnych zmiennych statystycznych są dostępne w postaci plików Parquet. Kolejny etap pipeline'u stanowi proces transformacji i ładowania danych do relacyjnej bazy danych PostgreSQL. Proces ten realizowany jest przez moduł ETL, którego zadaniem jest integracja danych pochodzących z wielu plików, ujednolicenie ich struktury, przypisanie identyfikatorów terytorialnych oraz zapis w docelowym modelu danych.

Pierwszym krokiem działania modułu jest odczyt konfiguracji środowiskowej zawierającej parametry połączenia do bazy danych oraz lokalizację folderu z plikami danych (Rys. 6.7). Zastosowanie pliku konfiguracyjnego umożliwia przenośność rozwiązania pomiędzy środowiskami oraz ogranicza występowanie stałych wartości (np. ścieżek lokalnych) bezpośrednio w kodzie.

```

CONFIG_PATH = Path(__file__).with_name("config.ini")

config = configparser.ConfigParser()
read_files = config.read(CONFIG_PATH, encoding="utf-8")

DB_CONFIG = {
    "host": config["database"]["host"],
    "port": config.getint("database", "port"),
    "dbname": config["database"]["dbname"],
    "user": config["database"]["user"],
    "password": config["database"]["password"],
}

```

Rysunek 6.7: Wczytywanie parametrów środowiskowych z pliku konfiguracyjnego config.ini

Następnie inicjowana jest struktura bazy danych, obejmująca tabele warstwy pośredniej (staging), tabele pomocnicze oraz tabelę faktów (Rys. 6.8). W module ETL zastosowano podejście polegające na tworzeniu tabel tylko w przypadku, gdy jeszcze nie istnieją, co pozwala na wielokrotne uruchamianie procesu bez konieczności ręcznego przygotowania struktury bazy. W szczególności wykorzystywane są:

- stg_miary jako staging dla danych w formie „płaskiej” (unit_id, rok, wartość, źródło),
- map_unitid_teryt jako tabela mapująca identyfikatory jednostek BDL na kody TERYT,
- stg_teryt jako techniczna tabela walidacyjna kodów TERYT,
- dim_year jako wymiar czasu,
- fact_biblioteki jako docelowa tabela faktów.

```

CREATE TABLE IF NOT EXISTS fact_biblioteki (
    teryt CHAR(7) NOT NULL,
    year SMALLINT NOT NULL,
    populacja NUMERIC(18,2),
    czytelnicy BIGINT,
    wypożyczenia BIGINT,
    księgozbiór BIGINT,
    biblioteki_i_filie INTEGER,
    wydatki NUMERIC(18,2),

    CONSTRAINT pk_fact PRIMARY KEY (teryt, year),
    CONSTRAINT fk_fact_teryt FOREIGN KEY (teryt) REFERENCES stg_teryt(teryt),
    CONSTRAINT fk_fact_year FOREIGN KEY (year) REFERENCES dim_year(year)
);

```

Rysunek 6.8: Definicja tabeli faktów fact_biblioteki z kluczami głównym i obcymi.

Kolejnym etapem jest załadowanie danych z plików Parquet do warstwy stagingowej (Rys. 6.9). Dane z każdego pliku zapisywane są w tabeli stg_miary wraz z identyfikatorem źródła (source), co umożliwia późniejszą integrację różnych miar w jednej tabeli faktów. Dzięki temu

można przetwarzać dane o populacji, czytelnikach, wypożyczeniach czy księgozbiorze w tym samym schemacie transformacji, mimo że pochodzą z różnych zbiorów. W tym miejscu realizowane jest także wstępne ujednolicenie pól do wspólnego zestawu kolumn.

```
execute_values(
    cur,
    """
    INSERT INTO stg_miary (unit_id, unit_name, year, value, teryt, source)
    VALUES %s
    """
    ,
    rows,
)
```

Rysunek 6.9: Zbiórzy zapis danych do tabeli stg_miary w ramach procesu ETL.

Istotnym krokiem integracji danych jest przypisanie kodu TERYT do wszystkich rekordów w stagingu. W danych źródłowych kod TERYT jest dostępny w zbiorze dotyczącym populacji, natomiast dla pozostałych zmiennych konieczne jest mapowanie na podstawie identyfikatora jednostki (unit_id). W tym celu tworzona jest tabela map_unitid_teryt budowana na bazie rekordów populacji, a następnie kod TERYT jest uzupełniany w pozostałych rekordach stagingu poprzez aktualizację na podstawie utworzonej mapy (Rys. 6.10). Rozwiązanie to pozwala na ujednolicenie klucza identyfikacyjnego w całym pipeline'ie oraz umożliwia dalsze łączenie danych w tabeli faktów.

```
def build_map_unitid_teryt_and_fill(conn):
    with conn.cursor() as cur:
        cur.execute(
            """
            INSERT INTO map_unitid_teryt (unit_id, teryt)
            SELECT DISTINCT unit_id, teryt
            FROM stg_miary
            WHERE source = 'populacja'
            AND teryt IS NOT NULL AND teryt <> ''
            ON CONFLICT (unit_id) DO NOTHING;
            """
        )

        cur.execute(
            """
            UPDATE stg_miary m
            SET teryt = d.teryt
            FROM map_unitid_teryt d
            WHERE m.teryt IS NULL
            AND m.unit_id = d.unit_id;
            """
        )
```

Rysunek 6.10: Fragment kodu realizujący mapowanie unit_id na kod TERYT w procesie ETL.

Po uzupełnieniu identyfikatorów możliwe jest przygotowanie wymiaru czasu (Rys. 6.11). W tabeli `dim_year` zapisywane są wszystkie lata występujące w stagingu, co zapewnia spójność analiz czasowych oraz pozwala kontrolować poprawność danych ładowanych do faktów.

```
def fill_dim_year(conn):  
    with conn.cursor() as cur:  
        cur.execute(  
            """  
            INSERT INTO dim_year (year)  
            SELECT DISTINCT year  
            FROM stg_miary  
            ORDER BY year  
            ON CONFLICT (year) DO NOTHING;  
            """  
        )
```

Rysunek 6.11: Tworzenie wymiaru czasu na podstawie lat występujących w danych źródłowych.

Dodatkowo w procesie ETL wykorzystywany jest plik TERC jako źródło referencyjne do walidacji i uzupełnienia listy kodów TERYT. Do tabeli `stg_teryt` ładowane są wyłącznie te kody, które faktycznie występują w stagingu, co ogranicza rozmiar tabeli walidacyjnej oraz zapewnia spójność pomiędzy danymi wejściowymi a strukturą bazy. Ten etap jest istotny z punktu widzenia integralności danych, ponieważ tabela `fact_biblioteki` posiada klucz obcy do `stg_teryt`, co uniemożliwia zapis rekordów z niepoprawnym lub nieznanym kodem TERYT.

Ostatnim etapem procesu jest zbudowanie tabeli faktów `fact_biblioteki`. Dane z `stg_miary` są agregowane do postaci jednego rekordu na parę (TERYT, rok), a wartości różnych miar są przenoszone do odpowiednich kolumn tabeli faktów. W tym miejscu realizowane jest także czyszczenie wartości liczbowych (m.in. zamiana separatorów dziesiętnych oraz usuwanie znaków nieliczbowych) oraz konwersja do typów liczbowych. Tabela faktów jest zasilana w sposób umożliwiający wielokrotne uruchamianie procesu ETL bez dublowania danych, dzięki czemu pipeline może być wykonywany cyklicznie w celu odświeżenia danych.

Na potrzeby kontroli przebiegu procesu ETL moduł wypisuje kolejne kroki przetwarzania w postaci komunikatów w konsoli (Rys. 6.12), co umożliwia szybkie wykrycie błędów oraz identyfikację etapu, na którym proces został przerwany. Przykładowy przebieg wykonania procesu:

```


D:\Python312\python.exe "C:\...\etl_parquet.py"
-> [PARQUET] Tworze strukture bazy (tabele dim_*, fact_*, stg_*)...
-> [PARQUET] Czyszcze staging...
-> [PARQUET] Laduje miary z plikow Parquet do stg_miary...
Laduje C:\...\populacja.parquet jako source='populacja'...
Laduje C:\...\czytelnicy_by_city.parquet jako source='czytelnicy'...
Laduje C:\...\wypozyczenia_ksiegozbioru_by_city.parquet jako source='wypozyczenia'...
Laduje C:\...\biblioteki_i_filie_by_city.parquet jako source='placowki'...
Laduje C:\...\ksiegozbor.parquet jako source='ksiegozbor'...
Laduje C:\...\wydatki.parquet jako source='wydatki'...
-> [PARQUET] Buduje mape unit_id -> teryt i uzupełniam teryt w stg_miary...
-> [PARQUET] Uzupełniam dim_year...
-> [PARQUET] Uzupełniam stg_teryt na podstawie TERC...
Laduje TERC z C:\...\TERC_Urzedowy_2025-10-22.csv...
-> [PARQUET] Buduje fact_biblioteki...
✓ [PARQUET] Gotowe. Dane sa w fact_biblioteki (commit).

```

Rysunek 6.12: Przebieg wykonania procesu tworzenia struktury bazy i ładowania danych.

6.3 Konfiguracja i modularność systemu

System został zaprojektowany w sposób modułowy, z wyraźnym rozdzieleniem odpowiedzialności pomiędzy poszczególne elementy rozwiązania, co ilustruje diagram aktywności pipeline'u z podziałem na moduły systemu (Rys. 6.21). Takie podejście pozwala na zachowanie czytelnej struktury kodu, ułatwia jego rozwój oraz umożliwia wprowadzanie zmian w wybranych częściach systemu bez konieczności modyfikowania całej logiki przetwarzania danych.



Rysunek 6.21: Diagram aktywności pipeline'u ETL z uwzględnieniem modularnej architektury systemu.

Kluczowe parametry działania systemu zostały wydzielone do zewnętrznego pliku konfiguracyjnego config.ini (Rys. 6.22). Zawiera on informacje dotyczące połączenia z bazą danych, lokalizacji katalogów z danymi oraz nazw plików wykorzystywanych w procesie ETL, w tym rejestru TERC. Dzięki temu konfiguracja środowiska pracy jest oddzielona od kodu źródłowego, co zwiększa elastyczność rozwiązania oraz pozwala na jego łatwe dostosowanie do innych warunków uruchomieniowych bez ingerencji w implementację.

```
[database]
host = adres hosta
port = numer portu
dbname = nazwa bazy danych
user = nazwa użytkownika
password = hasło

[paths]
data_dir = ścieżka do folderu
terc_filename = nazwa pliku TERC
```

Rysunek 6.22: Struktura pliku konfiguracyjnego config.ini

Architektura systemu opiera się na podziale pipeline'u na niezależne moduły odpowiadające kolejnym etapom przetwarzania danych. Pobieranie danych z API Banku Danych Lokalnych zostało zrealizowane w osobnym module, którego zadaniem jest wyłącznie komunikacja z zewnętrznym źródłem danych oraz zapis wyników do plików w formacie Parquet. Proces ładowania danych do relacyjnej bazy PostgreSQL został wydzielony do oddzielnego modułu ETL, w którym realizowane są operacje walidacji danych, uzupełniania identyfikatorów oraz budowy tabel docelowych. Nad całością czuwa moduł uruchamiający, odpowiedzialny za sterowanie kolejnością wykonywania poszczególnych etapów pipeline'u.

Modularna budowa systemu widoczna jest również wewnątrz samego procesu ETL, który został podzielony na mniejsze, logiczne funkcje realizujące konkretne zadania, takie jak inicjalizacja struktury bazy danych, ładowanie danych do tabel tymczasowych, mapowanie identyfikatorów jednostek terytorialnych czy zapis danych do tabeli faktów. Takie rozwiązanie poprawia czytelność kodu oraz ułatwia identyfikację i obsługę ewentualnych błędów.

Zastosowanie centralnej konfiguracji oraz modularnej architektury umożliwia bezpieczne, wielokrotne uruchamianie pipeline'u ETL. Poszczególne moduły korzystają z tych samych

parametrów konfiguracyjnych, co zapewnia spójność działania całego systemu. Jednocześnie wyraźny podział odpowiedzialności pomiędzy komponentami minimalizuje ryzyko powstawania niekontrolowanych zależności i ułatwia dalszą rozbudowę rozwiązania, na przykład o nowe źródła danych lub dodatkowe etapy analizy.

6.4 Optymalizacja procesu ETL

Jednym z celów projektowanego systemu było zapewnienie możliwie wysokiej wydajności procesu przetwarzania danych, przy jednoczesnym zachowaniu jego czytelności i niezawodności. W tym celu przeprowadzono porównanie dwóch wariantów pipeline'u ETL, różniących się formatem danych pośrednich wykorzystywanych pomiędzy etapem pobierania danych a ich ładowaniem do bazy danych.

W pierwszym wariancie pipeline wykorzystywał pliki w formacie CSV, natomiast w drugim wariancie zastosowano format Parquet. Oba rozwiązania realizowały tę samą logikę przetwarzania danych oraz korzystały z identycznych źródeł danych i schematu bazy, co pozwala na bezpośrednie porównanie ich wydajności. Testy wydajnościowe przeprowadzono w kontrolowanych warunkach, wykorzystując tryb testowy zaimplementowany w module pobierania danych (Rys.6.23, 6.24).

```
TEST_MODE = True  
MAX_PAGES = 3
```

Rysunek 6.23: Mechanizm trybu testowego ograniczającego zakres pobierania danych.


```
if TEST_MODE and page >= MAX_PAGES:  
    print(f" Zatrzymano po {MAX_PAGES} stronach (tryb testowy).")  
    break
```

Rysunek 6.24: Warunek zakończenia pobierania danych w trybie testowym.

Tryb ten umożliwia ograniczenie liczby stron danych pobieranych dla każdej zmiennej statystycznej, co pozwala na szybkie wykonywanie testów bez konieczności przetwarzania pełnego zbioru danych. W trakcie pomiarów ustawiono limit liczby stron pobieranych z API, a pozostałe elementy pipeline'u działały w trybie identycznym jak w wersji docelowej. Pomiar wydajności polegał na rejestracji całkowitego czasu wykonania pipeline'u, obejmującego zarówno etap pobierania danych, jak i ich zapis do relacyjnej bazy PostgreSQL. Każdy wariant

pipeline'u został uruchomiony wielokrotnie, aby ograniczyć wpływ czynników losowych, takich jak chwilowe opóźnienia sieciowe czy obciążenie systemu.

Czas CSV vs Parquet w trybie testowym



Rysunek 6.25: Wyniki pomiaru czasu przy użyciu wersji plików wykorzystujących CSV i Parquet.

Uzyskane wyniki (Rys. 6.25) wskazują, że pipeline oparty na plikach Parquet charakteryzuje się krótszym czasem wykonania w porównaniu do wariantu wykorzystującego format CSV. Różnice te są widoczne we wszystkich przeprowadzonych testach i wynikają głównie z bardziej efektywnego sposobu zapisu i odczytu danych w formacie kolumnowym, jakim jest Parquet. Na podstawie przeprowadzonych testów zdecydowano się na zastosowanie formatu Parquet jako domyślnego formatu danych pośrednich w projektowanym systemie. Pozwoliło to na skrócenie czasu działania pipeline'u ETL bez wprowadzania dodatkowej złożoności w jego architekturze oraz bez zmian w logice przetwarzania danych.

6.5 Obsługa błędów i spójność danych

Proces przetwarzania danych bibliotecznych został zaprojektowany w sposób zapewniający odporność na błędy oraz spójność danych na wszystkich etapach działania pipeline'u ETL. Mechanizmy te obejmują zarówno warstwę pozyskiwania danych z API GUS, jak i etap

ładowania danych do relacyjnej bazy PostgreSQL. Na etapie pobierania danych z API Banku Danych Lokalnych zastosowano mechanizm bezpiecznego wykonywania zapytań HTTP. W skrypcie odpowiedzialnym za warstwę Extract wykorzystano funkcję realizującą ponawianie zapytań w przypadku błędów połączenia oraz ustawiono limit czasu oczekiwania na odpowiedź serwera. W przypadku wielokrotnego niepowodzenia zapytania proces pobierania danej zmiennej zostaje przerwany, co zapobiega dalszemu przetwarzaniu niekompletnych danych.

Dodatkowo, w logice pobierania danych zaimplementowano kontrolowane przerywanie pętli paginacji w sytuacji wystąpienia błędu odpowiedzi (Rys. 6.13), dzięki czemu pipeline nie przechodzi do kolejnych etapów z nieprawidłowym zestawem danych.

```
resp = safe_get(current_url, current_params, HEADERS)
if resp is None:
    break
```

Rysunek 6.13: Warunek przerywania pętli pobierania danych w przypadku błędu odpowiedzi API.

Proces zapisu danych do bazy PostgreSQL został zaprojektowany w taki sposób, aby uniknąć sytuacji, w której do bazy trafiają dane niekompletne lub częściowo przetworzone. W tym celu cały proces ETL realizowany jest w ramach jednej transakcji bazy danych (Rys. 6.14). Oznacza to, że wszystkie operacje wykonywane podczas ładowania danych — od utworzenia wymaganych struktur, przez zapis danych tymczasowych, aż po zasilenie tabeli faktów — traktowane są jako jeden spójny etap. Dopiero po poprawnym zakończeniu wszystkich tych czynności zmiany są zapisywane w bazie danych (Rys. 6.15).

```
conn.autocommit = False
```

Rysunek 6.14: Wyłączenie trybu autocommit i inicjalizacja transakcyjnego przetwarzania danych.

```
conn.commit()
print(" [PARQUET] Gotowe. Dane sa w fact_biblioteki (commit).")
```

Rysunek 6.15: Zapis zmian do bazy danych po pomyślnym przetworzeniu danych.

W przypadku wystąpienia błędu na dowolnym etapie procesu ETL zapis danych zostaje cofnięty (Rys. 6.16), a baza danych wraca do stanu sprzed rozpoczęcia ładowania. Dzięki temu eliminowane jest ryzyko pozostawienia w bazie danych niepełnych lub niespójnych informacji, które mogłyby negatywnie wpłynąć na późniejsze analizy. Zastosowanie takiego mechanizmu

pozwała również na bezpieczne, wielokrotne uruchamianie całego pipeline'u ETL, bez konieczności ręcznego czyszczenia bazy danych w przypadku błędów lub przerwania procesu.

```
except Exception:
    conn.rollback()
    print(" [PARQUET] Wystąpił błąd podczas ETL - wykonano ROLLBACK wszystkich zmian.")
    raise
finally:
    conn.close()
```

Rysunek 6.16: Wycofanie zmian i zamknięcie połączenia w przypadku błędu procesu ETL.

Aby zapewnić poprawność i jednoznaczność danych zapisanych w bazie, zastosowano podstawowe mechanizmy kontroli spójności dostępne w relacyjnych bazach danych. Kluczowym elementem jest tabela faktów `fact_biblioteki`, w której każda obserwacja identyfikowana jest jednoznacznie przez parę wartości (`teryt`, `year`). Zastosowanie klucza złożonego oznacza, że dla danej jednostki terytorialnej oraz konkretnego roku w bazie może istnieć tylko jeden rekord. Eliminuje to ryzyko duplikowania danych oraz ułatwia analizę zmian wskaźników w czasie.

Dodatkowo w strukturze bazy zastosowano tabele referencyjne, które kontrolują poprawność kluczowych wymiarów analitycznych. Tabela `stg_teryt` pełni rolę słownika poprawnych kodów TERYT, zbudowanych na podstawie oficjalnego rejestru TERC. Z kolei tabela `dim_year` zawiera zbiór lat występujących w danych i zapewnia, że każdy rekord w tabeli faktów odnosi się do poprawnego okresu czasowego.

Powiązanie tabeli `fact_biblioteki` z tabelami `stg_teryt` oraz `dim_year` za pomocą kluczy obcych (Rys. 6.17) uniemożliwia zapis rekordów zawierających niepoprawne identyfikatory jednostek terytorialnych lub lat spoza zakresu danych. Dzięki temu dane przechowywane w bazie zachowują spójność zarówno w wymiarze przestrzennym, jak i czasowym.

```
CONSTRAINT pk_fact PRIMARY KEY (teryt, year),
CONSTRAINT fk_fact_teryt FOREIGN KEY (teryt) REFERENCES stg_teryt(teryt),
CONSTRAINT fk_fact_year FOREIGN KEY (year) REFERENCES dim_year(year)
```

Rysunek 6.17: Definicja klucza głównego oraz kluczy obcych w tabeli `fact_biblioteki`.

Proces ładowania danych do tabeli faktów został zaprojektowany w taki sposób, aby umożliwiać wielokrotne uruchamianie pipeline'u ETL bez ryzyka powielania danych. Ma to szczególne znaczenie w przypadku danych statystycznych publikowanych przez Główny Urząd

Statystyczny, które mogą być uzupełniane lub korygowane w kolejnych okresach. W trakcie zapisu danych do tabeli `fact_biblioteki` zastosowano mechanizm aktualizacji rekordów w przypadku wystąpienia konfliktu klucza głównego, określany jako UPSERT. Oznacza to, że jeżeli podczas ładowania danych pojawi się rekord dotyczący tej samej jednostki terytorialnej i tego samego roku, system nie tworzy nowego wpisu, lecz aktualizuje istniejący rekord.

Mechanizm ten realizowany jest za pomocą klauzuli `ON CONFLICT` (Rys. 6.18), która reaguje na konflikt pary (`teryt`, `year`). W przypadku jego wystąpienia wykonywana jest operacja aktualizacji pól tabeli faktów, zamiast próby wstawienia nowego rekordu. Dzięki temu tabela zawiera zawsze jeden, aktualny zestaw danych dla danej jednostki i roku.

```
ON CONFLICT (teryt, year) DO UPDATE SET
  populacja = EXCLUDED.populacja,
  czytelnicy = EXCLUDED.czytelnicy,
  wypozyczenia = EXCLUDED.wypozyczenia,
  ksiegozbior = EXCLUDED.ksiegozbior,
  biblioteki_i_filie = EXCLUDED.biblioteki_i_filie,
  wydatki = EXCLUDED.wydatki;
```

Rysunek 6.18: Mechanizm aktualizacji danych w tabeli `fact_biblioteki`.

W klauzuli aktualizacji wykorzystano alias `EXCLUDED`, który odnosi się do rekordu obliczonego w bieżącym przebiegu procesu ETL, a który nie mógł zostać wstawiony ze względu na konflikt. Pozwala to na nadpisanie wcześniej zapisanych wartości nowymi danymi, bez konieczności ręcznego usuwania lub modyfikowania rekordów w bazie danych. Zastosowanie mechanizmu UPSERT sprawia, że tabela `fact_biblioteki` zachowuje spójność w czasie, a dane mogą być w sposób kontrolowany aktualizowane wraz z kolejnymi uruchomieniami pipeline'u. Rozwiązanie to upraszcza proces utrzymania bazy danych oraz zapewnia, że wykorzystywane w analizach informacje zawsze odpowiadają najnowszemu stanowi danych źródłowych.

Cały proces przetwarzania danych został zaprojektowany jako spójny, sekwencyjny pipeline, w którym poszczególne etapy wykonywane są w ściśle określonej kolejności. Najpierw realizowany jest etap pobierania danych z API Banku Danych Lokalnych, a dopiero po jego poprawnym zakończeniu uruchamiany jest proces ETL odpowiedzialny za zapis danych do bazy PostgreSQL.

Sterowanie przebiegiem pipeline'u odbywa się w dedykowanym skrypcie uruchamiającym, który pełni rolę koordynatora całego procesu. Etap pobierania danych wykonywany jest jako osobny proces, a jego poprawne zakończenie jest warunkiem koniecznym do rozpoczęcia dalszego przetwarzania (Rys. 6.19). W przypadku wystąpienia błędu na etapie pozyskiwania danych pipeline zostaje przerwany, co zapobiega uruchomieniu procesu ETL na niekompletnych lub błędnych danych.

```
subprocess.run([sys.executable, str(api_parquet_path)], check=True)

etl_parquet.main()
```

Rysunek 6.19: Sekwencyjne wywołanie modułu pobierania danych i procesu ETL.

Dodatkowo proces ETL został wyposażony w własne mechanizmy obsługi błędów i transakcyjności, dzięki czemu nawet w przypadku problemów w trakcie zapisu danych do bazy system zachowuje spójność i nie pozostawia częściowo zapisanych wyników. Takie podejście pozwala traktować cały pipeline jako jedną logiczną całość, odporną na błędy na poszczególnych etapach. Uzupełnieniem kontroli przebiegu procesu jest pomiar całkowitego czasu wykonania pipeline'u (Rys. 6.20). Informacja ta umożliwia obserwację wydajności rozwiązania oraz identyfikację ewentualnych problemów w kolejnych uruchomieniach, co jest szczególnie istotne podczas testowania oraz dalszego rozwoju systemu.

```
start = time.perf_counter()

elapsed = time.perf_counter() - start
```

Rysunek 6.20: Pomiar czasu wykonania procesu przetwarzania danych.

7. WARSTWA ANALITYCZNA SYSTEMU – POWER BI

7.1 Charakterystyka warstwy analitycznej systemu

Power BI jest narzędziem klasy Business Intelligence, przeznaczonym do analizy danych oraz ich prezentacji w postaci interaktywnych raportów. Umożliwia ono integrację danych pochodzących z różnych źródeł, budowę modelu analitycznego oraz definiowanie miar i wskaźników wykorzystywanych w analizach. Z punktu widzenia użytkownika końcowego Power BI stanowi warstwę wizualizacyjno-analityczną systemu, której zadaniem jest umożliwienie interpretacji danych oraz wspomaganie procesów decyzyjnych, bez konieczności ingerencji w techniczne aspekty przetwarzania danych.

W niniejszej pracy Power BI pełni rolę końcowego narzędzia analitycznego systemu, które wykorzystuje dane przygotowane i udostępnione w relacyjnej bazie danych PostgreSQL w ramach procesu ETL. Narzędzie to nie uczestniczy w pozyskiwaniu danych źródłowych ani w ich pierwotnym oczyszczaniu, standaryzacji i integracji, które realizowane są w warstwie technicznej systemu z wykorzystaniem języka Python oraz relacyjnej bazy danych. Dzięki temu Power BI nie zastępuje procesu ETL ani warstwy składowania danych, lecz bazuje na danych już uporządkowanych i spójnych logicznie.

Jednocześnie w Power BI realizowane jest przetwarzanie o charakterze analitycznym, obejmujące agregację danych, wyznaczanie wskaźników względnych, porównań pomiędzy jednostkami terytorialnymi oraz obliczeń predykcyjnych. Przetwarzanie to odbywa się z wykorzystaniem modułu Power Query, języka DAX oraz osadzonych skryptów w języku Python, które wykonywane są w trakcie odświeżania danych raportu. Takie podejście pozwala na logiczne rozdzielenie odpowiedzialności pomiędzy warstwę techniczną systemu, odpowiadającą za poprawność, kompletność i spójność danych, a warstwę analityczną, której celem jest ich interpretacja oraz eksploracja przez użytkownika końcowego.

Zastosowanie Power BI w projektowanym systemie wynika z kilku istotnych przesłanek. Po pierwsze, narzędzie to umożliwia budowę modelu danych, w którym relacje pomiędzy tabelami, hierarchie administracyjne oraz miary analityczne są definiowane w sposób czytelny i kontrolowany. Pozwala to na zachowanie spójnego kontekstu analizy niezależnie od wybranego poziomu agregacji danych, takiego jak gmina, powiat czy województwo. Power BI


umożliwia również interaktywnych wizualizacji, które pozwalają analizować dane w różnych przekrojach czasowych i terytorialnych bez konieczności ingerencji w strukturę bazy danych lub kod procesu ETL. Narzędzie to jest powszechnie stosowane w administracji publicznej oraz analizach danych o charakterze statystycznym, co zwiększa potencjał praktycznego wykorzystania zaprojektowanego rozwiązania w rzeczywistych warunkach pracy urzędu gminy.

Raport analityczny opracowany w Power BI został zaprojektowany z myślą o pracowniku urzędu gminy, który nie posiada zaawansowanych kompetencji informatycznych ani programistycznych, lecz na co dzień pracuje z danymi liczbowymi i zestawieniami statystycznymi. Interfejs raportu oparto na jednolitym zestawie filtrów obejmujących rok, województwo, powiat, gminę oraz rodzaj gminy, które obowiązują na wszystkich stronach raportu i umożliwiają zachowanie spójnego kontekstu analizy. Zastosowane wizualizacje oraz miary pozwalają na szybkie porównanie wyników lokalnych z poziomem województwa i kraju, analizę trendów w czasie oraz interpretację relacji pomiędzy wybranymi wskaźnikami opisującymi działalność bibliotek publicznych.

7.2 Model analityczny danych

Model analityczny danych w narzędziu Power BI został zaprojektowany w oparciu o strukturę hurtowni danych utworzoną w relacyjnej bazie PostgreSQL oraz o potrzeby analityczne użytkownika końcowego systemu. Jego głównym celem jest umożliwienie spójnej analizy danych bibliotecznych w ujęciu czasowym i terytorialnym, przy jednoczesnym zachowaniu przejrzystości modelu oraz poprawności agregacji danych.

Centralnym elementem modelu analitycznego (Rys. 7.1) jest tabela faktów `fact_biblioteki`, która zawiera zagregowane dane statystyczne w układzie jednostka terytorialna – rok. Tabela ta stanowi podstawowe źródło danych liczbowych wykorzystywanych w raportach i wizualizacjach.



Rysunek 7.1: Diagram ERD przedstawiający model danych w warstwie analitycznej.

Każdy rekord tabeli faktów reprezentuje komplet informacji opisujących działalność bibliotek publicznych dla danej jednostki terytorialnej w określonym roku, obejmując m.in. liczbę czytelników, liczbę wypożyczeń, wielkość księgozbioru, liczbę placówek bibliotecznych oraz dane demograficzne. Do tabeli faktów dołączony jest wymiar czasu dim_year, który umożliwia analizę danych w ujęciu wieloletnim oraz budowę trendów czasowych. Relacja pomiędzy tabelą faktów a wymiarem czasu ma charakter relacji jeden-do-wielu i wykorzystywana jest do filtrowania danych według roku na wszystkich stronach raportu. Zastosowanie odrębnego wymiaru czasu zapewnia jednoznaczność filtracji oraz ułatwia interpretację zmian zachodzących w dłuższym horyzoncie czasowym.


Istotnym elementem modelu analitycznego są również tabele odwzorowujące hierarchię administracyjną kraju, obejmujące poziomy gminy, powiatu oraz województwa. Tabele te zostały zbudowane na podstawie rejestru TERC i pełnią rolę wymiarów umożliwiających analizę danych w różnych przekrojach przestrzennych. Powiązanie tabel administracyjnych z tabelą faktów odbywa się za pomocą wspólnego klucza TERYT, co zapewnia spójność danych oraz umożliwia filtrowanie wyników na dowolnym poziomie agregacji administracyjnej.

Relacje pomiędzy tabelami w modelu Power BI zostały zdefiniowane w sposób jednokierunkowy, co ogranicza ryzyko niejednoznacznych filtrów oraz błędnych agregacji danych. Taki sposób modelowania pozwala zachować pełną kontrolę nad kontekstem obliczeń miar analitycznych oraz zapewnia przewidywalność wyników prezentowanych w raportach. Hierarchia administracyjna wykorzystywana jest wyłącznie w warstwie analitycznej i prezentacyjnej, bez ingerencji w strukturę tabeli faktów.

Model analityczny został rozszerzony o dodatkowe tabele wykorzystywane na potrzeby analiz predykcyjnych. Tabele te zawierają wyniki obliczeń regresji liniowej wykonanych w module Power Query z wykorzystaniem języka Python. Dane predykcyjne obejmują zarówno wartości historyczne, jak i prognozowane, oznaczone odpowiednimi atrybutami identyfikującymi zakres danych oraz rodzaj serii (np. poziom kraju lub typ gminy). Dzięki temu możliwe jest prezentowanie prognoz na wykresach w sposób czytelny, z wyraźnym rozdzieleniem danych obserwowanych i przewidywanych.

Miary analityczne w modelu Power BI zostały zdefiniowane z wykorzystaniem języka DAX i opierają się na danych pochodzących z tabeli faktów oraz tabel predykcyjnych. W modelu zastosowano zarówno miary bazowe, odpowiadające bezpośrednio wartościom liczbowym przechowywanym w hurtowni danych, jak i miary pochodne, służące do obliczania wskaźników względnych, porównań oraz różnic pomiędzy poziomami administracyjnymi. Takie podejście umożliwia elastyczne tworzenie analiz bez konieczności modyfikowania struktury danych źródłowych.

Zaprojektowany model analityczny (Rys. 7.2) stanowi kompromis pomiędzy prostotą struktury a zakresem funkcjonalności analitycznej. Z jednej strony opiera się on na jednej, centralnej tabeli faktów, co ułatwia utrzymanie spójności danych i poprawność agregacji. Z drugiej strony, dzięki wykorzystaniu wymiarów administracyjnych, wymiaru czasu oraz tabel predykcyjnych, umożliwia prowadzenie złożonych analiz porównawczych i trendowych, dostosowanych do potrzeb użytkownika końcowego.



Rysunek 7.2: Implementacja modelu danych w PowerBI.

7.3. Zastosowane miary i wskaźniki

W ramach warstwy analitycznej systemu zdefiniowano zestaw miar bazowych oraz miar pochodnych (wskaźników), które stanowią podstawę analiz realizowanych w raportach Power BI. Miary te zostały utworzone w języku DAX i są obliczane dynamicznie w zależności od aktualnego kontekstu filtrowania, bez ingerencji w dane przechowywane w relacyjnej bazie danych. Miary bazowe odpowiadają bezpośrednio kolumnom liczbowym tabeli faktów fact_biblioteki i stanowią punkt wyjścia do dalszych obliczeń. Obejmują one w szczególności:

- liczbę czytelników,
- liczbę wypożyczeń,
- wielkość księgozbioru,
- liczbę placówek bibliotecznych,
- liczbę mieszkańców.


Miary te agregowane są na poziomie wybranego kontekstu analizy, takiego jak rok, gmina, powiat, województwo lub typ gminy. Dzięki temu możliwe jest zarówno analizowanie danych

pojedynczej jednostki terytorialnej, jak i prezentacja wartości zagregowanych dla większych obszarów administracyjnych. Na podstawie miar bazowych zdefiniowano zestaw wskaźników względnych, których celem jest umożliwienie porównań pomiędzy jednostkami o różnej skali oraz eliminacja wpływu liczby ludności na interpretację wyników. Do kluczowych wskaźników należą m.in.:

- liczba czytelników na 1 tys. mieszkańców,
- liczba wypożyczeń na mieszkańca,
- liczba placówek bibliotecznych na 10 tys. mieszkańców,
- liczba wypożyczeń na jednego czytelnika,
- liczba wypożyczeń na jeden wolumin księgozbioru.

Zastosowanie wskaźników względnych pozwala na bardziej obiektywną ocenę poziomu czytelnictwa oraz intensywności korzystania z zasobów bibliotecznych, niezależnie od wielkości analizowanej jednostki terytorialnej.

Zdefiniowane miary zostały zaprojektowane z uwzględnieniem mechanizmu kontekstu filtrów charakterystycznego dla Power BI. Wszystkie wskaźniki reagują na globalne filtry raportu, obejmujące rok, województwo, powiat, gminę oraz typ gminy. Zmiana wartości filtra powoduje automatyczne przeliczenie miar i aktualizację wszystkich wizualizacji na stronie raportu. Zastosowane miary i wskaźniki prezentowane są w raporcie Power BI w formie kart KPI oraz wykresów, które umożliwiają szybki przegląd kluczowych informacji (Rys. 7.3).



Rysunek 7.3: Przykładowa strona raportu prezentująca kluczowe wskaźniki biblioteczne.


7.4. Analiza danych historycznych

Analiza danych historycznych stanowi podstawowy element warstwy analitycznej zaprojektowanego systemu. Jej celem jest ocena zmian zachodzących w działalności bibliotek publicznych w długim okresie oraz identyfikacja kierunku i dynamiki tych zmian w ujęciu czasowym i terytorialnym. Analiza ta umożliwia odpowiedź na pytanie, w jaki sposób kształtował się poziom czytelnictwa oraz intensywność korzystania z usług bibliotecznych w przeszłości, a także czy obserwowane zmiany mają charakter trwały czy krótkookresowy.

W ramach analizy historycznej mierzone są zarówno wartości bezwzględne, jak i wskaźniki względne (per capita). Szczególny nacisk położono na wskaźniki przeliczone na liczbę mieszkańców, takie jak liczba czytelników na 1000 mieszkańców oraz liczba wypożyczeń na jednego mieszkańca. Zastosowanie miar per capita pozwala na porównywanie jednostek terytorialnych o zróżnicowanej wielkości populacji oraz eliminuje wpływ zmian demograficznych na interpretację wyników. Analiza prowadzona jest w oparciu o dane obejmujące lata 1999–2024, co umożliwia obserwację wieloletnich tendencji w badanych wskaźnikach. Tak długi horyzont czasowy pozwala na ograniczenie wpływu krótkookresowych wahań oraz zdarzeń incydentalnych, a tym samym sprzyja identyfikacji trwałych kierunków zmian.


Podstawową formą prezentacji danych historycznych są wykresy liniowe, ukazujące zmiany wartości wskaźników w kolejnych latach (Rys. 7.4). Wizualizacje te umożliwiają jednoczesne przedstawienie danych dla wybranej jednostki terytorialnej, wartości referencyjnych na poziomie województwa oraz wartości zagregowanych dla całego kraju. Dzięki temu użytkownik może ocenić, czy obserwowane zmiany mają charakter lokalny, czy wpisują się w ogólnokrajowy trend.

Wypożyczenia na mieszkańca – gmina vs województwo vs Polska:



Rysunek 7.4: Wykres liniowy prezentujący zmianę ilości wypożyczeń na jednego mieszkańca na przestrzeni lat.

Istotnym elementem analizy historycznej jest możliwość przeprowadzenia analizy zmian rok do roku, która pozwala na ocenę bieżącej dynamiki badanych wskaźników. Zmiana rok do roku informuje o tym, o ile dana wartość wzrosła lub spadła w porównaniu z rokiem poprzednim, niezależnie od jej poziomu bezwzględnego (Rys. 7.5). Takie podejście umożliwia identyfikację lat charakteryzujących się nagłymi spadkami lub wzrostami analizowanych wskaźników, które mogą być związane z decyzjami organizacyjnymi, zmianami finansowania lub innymi czynnikami zewnętrznymi.



Rysunek 7.5: Przykład porównania danych historycznych pomiędzy wybranymi latami.

Uzupełnieniem analizy zmian krótkookresowych jest identyfikacja trendu długookresowego, rozumianego jako ogólny kierunek zmian badanych wskaźników w analizowanym okresie. Analiza trendu pozwala na ocenę, czy w dłuższej perspektywie obserwowany jest wzrost, spadek czy stabilizacja poziomu czytelnictwa oraz intensywności korzystania z bibliotek, niezależnie od rocznych wahań wartości.

Dzięki zastosowaniu wspólnego wymiaru czasu oraz globalnych filtrów raportu użytkownik może analizować dane w różnych przekrojach terytorialnych, takich jak województwo, powiat, gmina lub typ gminy, przy zachowaniu pełnego zakresu czasowego danych. Takie podejście umożliwia m.in. porównanie dynamiki zmian pomiędzy różnymi typami gmin, ocenę pozycji danej jednostki względem średniej krajowej oraz identyfikację jednostek charakteryzujących się stabilnie wysokimi lub niskimi wartościami wskaźników.

Analiza danych historycznych w zaprojektowanym systemie koncentruje się na interpretacji kierunków zmian oraz ich względnej skali, a nie na analizie pojedynczych wartości liczbowych. Z punktu widzenia użytkownika końcowego, w szczególności pracownika administracji samorządowej, stanowi ona podstawowe narzędzie oceny dotychczasowych działań oraz identyfikacji obszarów wymagających dalszej obserwacji lub interwencji. Uzyskane wyniki stanowią jednocześnie punkt odniesienia dla dalszych analiz, w tym analiz prognostycznych, omówionych w kolejnym podrozdziale.

7.5. Predykcja wybranych wskaźników

Uzupełnieniem analizy danych historycznych jest moduł predykcyjny, którego celem jest oszacowanie możliwego kierunku zmian wybranych wskaźników w kolejnych latach. Predykcja w zaprojektowanym systemie pełni funkcję wspomagającą analizę, a jej zadaniem jest wskazanie potencjalnej skali i kierunku zmian wynikających z dotychczas obserwowanych trendów.

W analizach predykcyjnych wykorzystano wskaźniki względne (per capita), w szczególności liczbę czytelników na 1 tys. mieszkańców, co zapewnia porównywalność wyników w czasie oraz pomiędzy różnymi jednostkami terytorialnymi. Predykcja została przeprowadzona oddzielnie od analizy danych historycznych, a jej zakres obejmuje lata 2025–2030, przy czym rok 2024 stanowi ostatnią obserwację historyczną, wykorzystywaną do estymacji modelu.

Do budowy prognoz zastosowano prostą regresję liniową, w której zmienną objaśniającą jest rok, natomiast zmienną objaśnianą wartość analizowanego wskaźnika. Model został zbudowany w środowisku Python z wykorzystaniem biblioteki *scikit-learn* i zaimplementowany bezpośrednio w narzędziu Power Query w Power BI. Dane wejściowe do modelu obejmują wyłącznie obserwacje historyczne z lat **1999–2024**, dla których dostępne są kompletne wartości wskaźnika.


Zastosowanie języka Python w Power Query umożliwiło:

- automatyczne dopasowanie modelu regresji do danych historycznych,
- wygenerowanie prognoz dla kolejnych lat do roku 2030,
- zapisanie wyników w postaci tabel wykorzystywanych bezpośrednio w modelu analitycznym Power BI.

W wyniku obliczeń powstały dwie tabele analityczne: `pred_pl`, zawierająca prognozy dla poziomu krajowego, oraz `typ_year`, obejmująca analogiczne obliczenia wykonane oddzielnie dla poszczególnych typów gmin. Obie tabele zawierają informacje o roku, wartości rzeczywistej (dla lat historycznych), wartości prognozowanej oraz oznaczenie zakresu danych (dane historyczne lub prognoza). Takie rozdzielenie umożliwia niezależną analizę trendów ogólnokrajowych oraz porównanie dynamiki zmian pomiędzy segmentami jednostek samorządu terytorialnego.

Wyniki predykcji zaprezentowano w raporcie Power BI w formie wykresów liniowych, na których dane historyczne oraz wartości prognozowane zostały jednoznacznie rozróżnione (Rys. 7.6). Dzięki temu użytkownik może w prosty sposób odróżnić obserwacje rzeczywiste od wartości prognozowanych, wyznaczonych na podstawie dotychczasowego trendu.


Regresja liniowa czytelników na 1 tys. mieszkańców – Polska (prognoza do 2030):



Rysunek 7.6: Wykres przedstawiający ilość czytelników na 1 tys. mieszkańców na przestrzeni lat oraz wartości

Dodatkowo zaprezentowano porównanie trendów czytelnictwa dla poszczególnych typów gmin (Rys. 7.7). Linie trendu zostały wyznaczone na podstawie danych historycznych i przedłużone do roku 2030, co umożliwia ocenę różnic w kierunku oraz dynamice zmian pomiędzy gminami miejskimi, miejsko-wiejskimi i wiejskimi.

Porównanie trendów czytelnictwa według typu gminy – regresja liniowa (1999–2030):



Rysunek 7.7: Wykres przedstawiający porównanie trendów czytelnictwa dla poszczególnych typów gminy.

W celu syntetycznego podsumowania wyników predykcji w raporcie zaprezentowano miary KPI opisujące zmianę prognozowanego poziomu czytelnictwa pomiędzy rokiem 2024 a 2030, zarówno w ujęciu bezwzględnym, jak i procentowym. Miary te umożliwiają szybką ocenę skali przewidywanych zmian oraz porównanie ich poziomem krajowym a poszczególnymi typami gmin.

Aby ocenić jakość dopasowania modelu do danych historycznych, dla okresu 1999–2024 wyznaczono błąd RMSE (Root Mean Square Error) pomiędzy wartościami rzeczywistymi a wartościami obliczonymi przez model regresji. Metryka ta pozwala liczbowo ocenić, jak bardzo wyniki modelu różnią się od rzeczywistych danych i pokazuje, że prognoza nie jest przypadkowym zbiorem wartości, lecz wynika z dotychczasowego kierunku zmian.

Dla danych historycznych z lat 1999–2024 uzyskano wartość RMSE równą 6,58. Oznacza to, że model myli się średnio o około 6,6 czytelnika na 1000 mieszkańców względem wartości rzeczywistych. W porównaniu z typowym poziomem analizowanego wskaźnika jest to różnica niewielka, co potwierdza, że model dobrze odwzorowuje przebieg danych historycznych i może być używany do orientacyjnej oceny przyszłego kierunku zmian.

Zastosowany model regresji liniowej stanowi uproszczone podejście do prognozowania i nie uwzględnia czynników zewnętrznych, takich jak zmiany demograficzne, decyzje polityczne czy zdarzenia losowe. Jego celem jest wskazanie ogólnego kierunku i potencjalnej skali zmian, a nie formułowanie wiążących prognoz statystycznych. Z punktu widzenia użytkownika

końcowego, w szczególności pracownika administracji samorządowej, moduł predykcyjny stanowi narzędzie wspomagające interpretację danych historycznych oraz analizę możliwych scenariuszy rozwoju w kolejnych latach.

8. OCENA DZIAŁANIA SYSTEMU

8.1. Poprawność i kompletność przetwarzania danych

Proces walidacji poprawności importu miał na celu wykazanie, że dane pobrane z interfejsu API Banku Danych Lokalnych (BDL) zostały bezbłędnie przetworzone i zapisane w docelowej tabeli faktów. Walidację przeprowadzono metodą porównania punktowego (*spot-check*) oraz weryfikacji integralności i typów danych w bazie PostgreSQL.

Test zgodności punktowej (Spot-check):

Wybrano losową jednostkę terytorialną (np. Gmina Kłodzko, TERYT: 0208021) dla roku 2023 i porównano wartości wyświetlane bezpośrednio w portalu BDL GUS z wartościami zapisanymi w tabeli fact_biblioteki.

Tabela 8.1: Test zgodności punktowej dla gminy Kłodzko w roku 2023.

Nazwa miary	Wartość w API GUS	Wartość w fact_biblioteki	Status walidacji
Czytelnicy	2608	2608	zgodna
Wypożyczenia	67295	67295	zgodna
Księgozbiór	91611	91611	zgodna
Populacja	24,81	24,81	zgodna
Biblioteki i filie	2	2	zgodna
Wydatki	1151995	1151995	zgodna

Uzyskane wyniki porównawcze dla wybranej jednostki testowej (Gmina Kłodzko, rok 2023) wykazują pełną zgodność danych przechowywanych w tabeli faktów z oficjalnymi danymi udostępnianymi przez portal Banku Danych Lokalnych GUS. Wykazanie identycznych wartości dla wszystkich kluczowych miar statystycznych stanowi dowód na poprawność działania mechanizmu pobierania danych z interfejsu API.

Weryfikacja kompletności zbioru (Row Count):

Kluczowym etapem walidacji poprawności działania systemu było wykazanie, że proces ETL (Extract, Transform, Load) nie powoduje utraty danych na żadnym z etapów przetwarzania. Weryfikację przeprowadzono poprzez porównanie liczby unikalnych obiektów wejściowych z liczbą rekordów finalnie zapisanych w tabeli faktów fact_biblioteki.

Do weryfikacji wykorzystano zapytania SQL wykonane bezpośrednio w systemie zarządzania bazą danych PostgreSQL (Rys. 8.1). Porównano liczbę unikalnych par identyfikatora terytorialnego i roku (stanowiących klucz główny tabeli faktów) w warstwie tymczasowej (*staging*) oraz docelowej.

```

biblioteki=# SELECT count(DISTINCT (teryt, year)) FROM stg_miary;
count
-----
106983
(1 wiersz)

biblioteki=# SELECT count(*) FROM fact_biblioteki;
count
-----
106983
(1 wiersz)

```

Rysunek 8.1: Weryfikacja kompletności zbioru danych.

Uzyskanie identycznej liczby rekordów na obu etapach (zgodność 1:1) dowodzi, że:

Paginacja API: Mechanizm pobierania danych z API GUS obsłużył komplet stron wyników bez pomijania rekordów między paczkami danych (*page-size*).

Agregacja i transformacja: Proces konsolidacji miar z różnych plików Parquet (populacja, czytelnicy, wypożyczenia itd.) do jednego wiersza tabeli faktów przebiegł bezstratnie.

Weryfikacja unikalności rekordów:

Fundamentalnym założeniem modelu danych jest to, że dla jednej jednostki terytorialnej w danym roku może istnieć wyłącznie jeden rekord w tabeli faktów. Zostało to wymuszone na poziomie bazy danych poprzez nałożenie klucza głównego złożonego z par (teryt, year). W celu potwierdzenia, że w tabeli nie występują duplikaty (co mogłoby zafałszować sumy kontrolne w Power BI), wykonano zapytanie SQL wyszukujące grupy o tym samym kluczu, które występują więcej niż raz (Rys. 8.2). Brak wyników oznacza, że każda para (teryt, year) jest unikalna w skali całej bazy danych, oraz udowadnia skuteczność UPSERT. Zastosowanie klauzuli ON CONFLICT zapobiegło dublowaniu danych przy jednoczesnym zachowaniu unikalności rekordów.

```

biblioteki=# SELECT teryt, year, COUNT(*)
biblioteki=# FROM public.fact_biblioteki
biblioteki=# GROUP BY teryt, year
biblioteki=# HAVING COUNT(*) > 1;
 teryt | year | count
-----+-----+-----
(0 wierszy)

```

Rysunek 8.2: Weryfikacja unikalności rekordów w tabeli faktów.

Weryfikacja kompletności transformacji (Null Check):

Podczas testów przeprowadzono zapytanie filtrujące rekordy, w których konwersja mogła się nie powieść (wartości NULL w kolumnach miar). Wynik zapytania (Rys. 8.3) zwrócił 0 rekordów, co dowodzi, że funkcja transformująca w Pythonie skutecznie obsłużyła 100% pobranych obserwacji, eliminując ewentualne błędy formatowania danych źródłowych.

```
biblioteki=# SELECT count(*)
biblioteki=# FROM public.fact_biblioteki
biblioteki=# WHERE populacja IS NULL
biblioteki=#      OR czytelnicy IS NULL
biblioteki=#      OR wypożyczenia IS NULL
biblioteki=#      OR księgozbiór IS NULL
biblioteki=#      OR biblioteki_i_filie IS NULL;
count
-----
      0
(1 wiersz)
```


Rysunek 8.3: Weryfikacja kompletności transformacji w tabeli faktów.

8.2. Użyteczność systemu z perspektywy użytkownika gminnego

Ocena użyteczności systemu została przeprowadzona z perspektywy pracownika urzędu gminy, który wykorzystuje dane statystyczne w analizach planistycznych, sprawozdawczych oraz porównawczych. System został zaprojektowany jako narzędzie wspierające samodzielną pracę analityczną, zapewniające dostęp do uporządkowanych danych bibliotecznych oraz możliwość ich interpretacji w różnych kontekstach decyzyjnych. Poniższe scenariusze prezentują praktyczne wykorzystanie systemu w codziennej pracy urzędniczej:

Scenariusz 1: Analiza dynamiki czytelnictwa w ujęciu rocznym


Użytkownik, przygotowując roczne sprawozdanie z działalności kulturalnej, analizuje zmianę liczby czytelników oraz wypożyczeń rok do roku. Wykorzystuje do tego celu wykresy dynamiki w Power BI (Rys. 8.4), które automatycznie wyliczają wartości dla wybranych lat. Dzięki temu urzędnik może błyskawicznie zidentyfikować nagłe wahania aktywności mieszkańców, co pozwala na sformułowanie wniosków dotyczących skuteczności przeprowadzonych akcji promujących czytelnictwo.



Rysunek 8.4: Strona raportu przedstawiająca wykresy zmiany liczby czytelników oraz wypożyczeń w wybranych latach.

Scenariusz 2: Porównanie efektywności gminy na tle kraju i województwa


W celu obiektywnej oceny pozycji jednostki, pracownik urzędu zestawia lokalne wskaźniki względne z wartościami referencyjnymi. Korzystając z interaktywnego dashboardu (Rys. 8.5), urzędnik może zauważyć np. sytuację, w której gmina mimo ogólnopolskich trendów spadkowych, notuje wyraźny wzrost liczby czytelników na 1 tys. mieszkańców w ostatnich latach, przekraczając średnią dla województwa i kraju. Dodatkowy wykres odchylenia pozwala precyzyjnie wyliczyć deltę wypożyczeń względem średniej krajowej, co stanowi silny argument merytoryczny przy ocenie efektywności lokalnej biblioteki na tle innych jednostek.



Rysunek 8.5: Strona raportu zawierająca zestawienie liczby czytelników, oraz wypożyczeń w porównaniu z poziomem województwa oraz kraju

Scenariusz 3: Wykorzystanie prognoz w planowaniu budżetu

Podczas prac nad projektem budżetu, urzędnik analizuje moduł predykcyjny w celu oszacowania przyszłego zapotrzebowania na usługi biblioteczne w kontekście trendów makroekonomicznych. Wykorzystuje on wizualizację regresji liniowej (Rys. 8.6), która prezentuje historyczny poziom czytelnictwa w Polsce wraz z prognozą do 2030 roku. Dodatkowo użytkownik analizuje wykres trendów od 1999 do 2030 roku w podziale na gminy miejskie, wiejskie oraz miejsko-wiejskie. Sprawdza, czy spadek aktywności w jego gminie jest głębszy, czy łagodniejszy niż wyznaczony trend dla analogicznego typu gmin w skali kraju. Jeżeli prognoza ogólnokrajowa dla danego typu gminy wskazuje na dalszą regresję, urzędnik może zarekomendować przesunięcie środków z utrzymania infrastruktury na intensywne działania promocyjne lub cyfryzację, mające na celu odwrócenie niekorzystnej tendencji.



Rysunek 8.6: Wizualizacja modułu predykcyjnego i analizy trendów długookresowych.

Podsumowując, automatyzacja procesu sprawia, że użytkownik pracuje wyłącznie na danych już uporządkowanych. Przedstawione scenariusze dowodzą, że system umożliwia elastyczne wykorzystanie danych bibliotecznych oraz wspiera procesy decyzyjne poprzez zapewnienie wiarygodnego źródła informacji analitycznych.

8.3. Ograniczenia zaprojektowanego rozwiązania

Zaprojektowany system analityczny opiera się na danych statystycznych udostępnianych przez Bank Danych Lokalnych GUS. Zakres analiz możliwych do przeprowadzenia w systemie jest bezpośrednio związany z zakresem, strukturą oraz poziomem agregacji danych publikowanych w tym źródle. Dane te prezentowane są w ujęciu rocznym oraz na poziomie jednostek samorządu terytorialnego, co wyznacza szczegółowość analiz oraz wpływa na sposób interpretacji uzyskiwanych wyników.

Istotnym ograniczeniem rozwiązania jest sposób aktualizacji danych w warstwie analitycznej. Dane wykorzystywane w systemie są pozyskiwane z Banku Danych Lokalnych GUS w trakcie uruchamiania pipeline'u ETL, a ich aktualność zależy zarówno od momentu publikacji danych w statystyce publicznej, jak i od częstotliwości uruchamiania procesu przetwarzania danych. W efekcie analizy realizowane w systemie odzwierciedlają stan danych dostępnych w chwili ostatniego wykonania procesu ETL, co sprzyja analizom okresowym i retrospektywnym.

Zakres analiz predykcyjnych dostępnych w systemie wynika z przyjętych założeń projektowych oraz charakteru danych historycznych. Prognozy przygotowywane są na podstawie obserwowanych zmian wartości wskaźników w czasie i służą do wskazania możliwego kierunku dalszych zmian. Uzyskiwane wyniki mają charakter orientacyjny i wspierają analizę planistyczną, przy czym ich interpretacja wymaga uwzględnienia ograniczeń wynikających z prostoty zastosowanego podejścia prognostycznego.

Z punktu widzenia technicznego system opiera się na architekturze przetwarzania wsadowego. Proces ETL realizowany jest w sposób sekwencyjny i cykliczny, co wpływa na czas potrzebny do pełnego odświeżenia danych w hurtowni. Wraz ze wzrostem wolumenu przetwarzanych danych lub rozszerzeniem zakresu systemu o dodatkowe zmienne statystyczne może ulec wydłużeniu czas wykonania procesu przetwarzania. Ograniczenie to wynika z charakteru przyjętej architektury oraz zasobów środowiska, w którym uruchamiany jest system.

Kolejnym uwarunkowaniem jest konieczność standaryzacji danych integrowanych w hurtowni danych. Struktura systemu zakłada spójność i jednoznaczność danych analitycznych, co wymaga dostosowania danych wejściowych do przyjętego modelu danych. Ograniczenie to

wpływa na sposób oraz tempo włączania nowych źródeł informacji do systemu, jednocześnie zapewniając porównywalność wyników analiz oraz stabilność działania warstwy analitycznej.

Przedstawione ograniczenia wynikają z przyjętych decyzji projektowych oraz charakteru danych statystycznych wykorzystywanych w systemie. Określają one ramy zastosowania zaprojektowanego rozwiązania oraz wskazują obszary, które mogą stanowić kierunek dalszego rozwoju systemu w przyszłych pracach badawczych lub wdrożeniowych.

9. PODSUMOWANIE I WNIOSKI

9.1. Osiągnięte cele pracy

Celem niniejszej pracy było zaprojektowanie i wykonanie systemu analitycznego umożliwiającego analizę danych bibliotecznych pochodzących z oficjalnych źródeł statystyki publicznej, ze szczególnym uwzględnieniem potrzeb analitycznych jednostek samorządu terytorialnego. Realizacja tego celu obejmowała zarówno aspekty techniczne związane z przetwarzaniem danych, jak i zagadnienia dotyczące ich późniejszego wykorzystania w procesach analitycznych i decyzyjnych.

W ramach pracy zaprojektowano i zaimplementowano kompletny pipeline przetwarzania danych, obejmujący pozyskiwanie danych z Banku Danych Lokalnych GUS, ich transformację oraz zapis w relacyjnej bazie danych pełniącej rolę hurtowni danych. Opracowany proces ETL zapewnia spójność, kompletność oraz powtarzalność przetwarzania danych, a zastosowane mechanizmy walidacji i integralności pozwalają na bezpieczne wielokrotne uruchamianie procesu bez ryzyka utraty lub duplikacji danych.

Zrealizowany został również cel związany z zaprojektowaniem logicznego modelu danych dostosowanego do analiz czasowo-przestrzennych. Struktura hurtowni danych umożliwia jednoznaczne powiązanie danych bibliotecznych z jednostkami terytorialnymi oraz określonymi latami, co stanowi podstawę do prowadzenia analiz porównawczych i trendowych. Przyjęte rozwiązania projektowe zapewniają spójność danych oraz ułatwiają ich dalsze wykorzystanie w warstwie analitycznej.

Istotnym elementem pracy było przygotowanie warstwy analitycznej systemu, umożliwiającej eksplorację danych oraz ich interpretację z perspektywy użytkownika gminnego. Zaprezentowane w pracy przykładowe wizualizacje i analizy potwierdzają możliwość wykorzystania systemu do analizy zmian w czasie, porównań pomiędzy jednostkami samorządu terytorialnego oraz budowy prostych analiz prognostycznych. Warstwa analityczna stanowi demonstrację praktycznych możliwości systemu i pokazuje, w jaki sposób dane zgromadzone w hurtowni mogą być wykorzystywane w rzeczywistych zastosowaniach.

Osiągniętym celem pracy jest także wykazanie, że dane statystyki publicznej mogą być efektywnie integrowane i przetwarzane w ramach spójnego systemu analitycznego, który wspiera procesy analityczne i planistyczne w administracji samorządowej. Zaprojektowane rozwiązanie umożliwia uporządkowane korzystanie z danych historycznych oraz ich analizę w długim horyzoncie czasowym, co ma istotne znaczenie przy ocenie zmian zachodzących w obszarze działalności bibliotek publicznych.

9.2. Możliwości dalszego rozwoju systemu

Zaprojektowany i zaimplementowany w ramach pracy system analityczny stanowi funkcjonalną podstawę do dalszego rozwoju zarówno w warstwie technicznej, jak i analitycznej. Przyjęta architektura oraz modularna budowa pipeline'u przetwarzania danych umożliwiają stopniowe rozszerzanie zakresu analiz bez konieczności przebudowy całego rozwiązania.

Jednym z naturalnych kierunków rozwoju systemu jest rozszerzenie zakresu wykorzystywanych danych. Obecnie analiza koncentruje się na wybranych wskaźnikach opisujących działalność bibliotek publicznych oraz danych demograficznych. W przyszłości możliwe jest włączenie dodatkowych zmiennych dostępnych w Banku Danych Lokalnych, w szczególności danych finansowych lub wskaźników dotyczących zatrudnienia i oferty kulturalnej, co pozwoliłoby na pogłębienie analiz i szersze spojrzenie na funkcjonowanie bibliotek w kontekście lokalnym.

Rozwój systemu może również obejmować dalsze prace nad analizami prognostycznymi. Obecne rozwiązanie pokazuje możliwość wykorzystania danych historycznych do szacowania kierunku zmian w przyszłych latach. W kolejnych etapach możliwe byłoby zastosowanie bardziej złożonych metod analizy danych, uwzględniających większą liczbę zmiennych lub różne scenariusze rozwoju, przy zachowaniu analitycznego charakteru systemu.

Z perspektywy technicznej system może zostać rozszerzony o mechanizmy automatyzacji uruchamiania pipeline'u ETL, na przykład poprzez harmonogram zadań lub integrację z narzędziami orkiestrującymi procesy przetwarzania danych. Pozwoliłoby to na regularne odświeżanie danych bez konieczności ręcznego uruchamiania skryptów, przy zachowaniu pełnej kontroli nad przebiegiem procesu.

Możliwy dalszy rozwój systemu dotyczy również sposobu organizacji danych w warstwie składowania. W zaprojektowanym rozwiązaniu model relacyjny został celowo uproszczony i ograniczony do jednej tabeli faktów, wymiaru czasu oraz tabel technicznych wspierających proces ETL. Takie podejście pozwoliło skupić się na poprawności, spójności i powtarzalności przetwarzania danych, a jednocześnie przenieść część logiki analitycznej do warstwy prezentacji. W przypadku rozszerzenia zakresu analiz lub udostępniania danych większej liczbie odbiorców możliwe byłoby jednak stopniowe przenoszenie wybranych elementów modelu analitycznego do bazy danych. Dotyczyłoby to w szczególności tych informacji, które obecnie funkcjonują jako atrybuty w modelu raportowym, a które mogłyby pełnić rolę trwałych i jednoznacznie zdefiniowanych wymiarów w warstwie składowania. Taki kierunek rozwoju pozwoliłby na zwiększenie niezależności danych od konkretnego narzędzia analitycznego oraz na wykorzystanie hurtowni danych jako samodzielnego źródła analiz, przy zachowaniu spójności i czytelności modelu relacyjnego.

Podsumowując, zaprojektowany system stanowi elastyczną bazę do dalszych prac rozwojowych. Jego architektura oraz przyjęte rozwiązania projektowe umożliwiają stopniowe rozszerzanie funkcjonalności zarówno w obszarze przetwarzania danych, jak i ich analizy, bez konieczności zasadniczych zmian w istniejącej strukturze systemu.

BIBLIOGRAFIA

- Chodkowska-Gyurics A.: „Hurtownie danych. Teoria i praktyka.”; Warszawa: Wydawnictwo Naukowe PWN, 2014
- Fowler M.: „UML w kropelce wersja 2.0”; Warszawa: Oficyna Wydawnicza LTP, 2005
- Géron A.: „Uczenie maszynowe z użyciem Scikit-Learn, Keras i TensorFlow.”; Gliwice: Helion, 2023
- Inmon W.H.: “Building the Data Warehouse”; John Wiley & Sons, 1992
- Kimball, R., Ross, M.: “The Data Warehouse Toolkit: The Definitive Guide to Dimensional Modeling”; John Wiley & Sons, 2013
- Larman C.: „UML i wzorce projektowe. Analiza i projektowanie obiektowe oraz iteracyjny model wytwarzania aplikacji.”; Gliwice: Helion, 2011
- McKinney W.: „Python w analizie danych. Przetwarzanie danych za pomocą pakietów pandas i NumPy oraz środowiska Jupyter.”; Gliwice: Helion, 2023
- Rozema M., Vlootman H.: „DAX i Power BI w analizie danych : tworzenie zaawansowanych i efektywnych analiz dla biznesu”; Gliwice: Helion, 2023
- Sommerville I.: „Inżynieria oprogramowania.”; Warszawa: Wydawnictwo Naukowe PWN, 2020
- Ustawa z dnia 27 czerwca 1997 r. o bibliotekach (Dz.U. 1997 nr 85 poz. 539 z późn. zm.).
- Główny Urząd Statystyczny, Bank Danych Lokalnych GUS. - <https://bdl.stat.gov.pl>
- Główny Urząd Statystyczny, Dokumentacja API Banku Danych Lokalnych. - <https://api.stat.gov.pl>
- Główny Urząd Statystyczny, Rejestr TERYT. - <https://eteryt.stat.gov.pl>
- Dokumentacja PostgreSQL. - <https://www.postgresql.org/docs/>
- Dokumentacja języka Python 3 - <https://docs.python.org/3/>
- Dokumentacja biblioteki pandas. - <https://pandas.pydata.org/docs/>
- Dokumentacja biblioteki requests. - <https://requests.readthedocs.io>
- Dokumentacja biblioteki scikit-learn. - <https://scikit-learn.org/0.21/documentation.html>
- Dokumentacja biblioteki psycopg2 - <https://www.psycopg.org/docs/>
- Dokumentacja biblioteki numpy - <https://numpy.org/doc/>
- Dokumentacja biblioteki tqdm - <https://tqdm.github.io/>

SPIS RZECZY

Spis rysunków

Rysunek 2.1: Wybrane wskaźniki dla gminy Kłodzko na Portalu GUS BDL.....	14
Rysunek 3.1: Wykres przedstawiający liczbę czytelników na 1 tys. mieszkańców w poszczególnych latach.	16
Rysunek 4.1 Architektura logiczna systemu	20
Rysunek 5.1: Fragment tabeli stagingowej w bazie danych PostgreSQL.	28
Rysunek 5.2: Fragment tabeli map_unitid_teryt w bazie danych PostgreSQL.	29
Rysunek 5.3: Fragment tabeli faktów w bazie danych PostgreSQL.....	31
Rysunek 6.1: Przykład zapytania pobierającego listę tematów BDL.	35
Rysunek 6.2: Wynik pobrania listy tematów głównych z API Banku Danych Lokalnych GUS.	36
Rysunek 6.3: Przykład definicji parametrów przy realizacji zapytania z użyciem parent-id.	36
Rysunek 6.4: Przykładowe określenie parametrów zapytania dla wybranego podtematu.	37
Rysunek 6.5: Definicja parametrów dla zapytania do API BDL.....	37
Rysunek 6.6: Mechanizm ponawiania prób w przypadku problemów połączenia z API.	37
Rysunek 6.7: Wczytywanie parametrów środowiskowych z pliku konfiguracyjnego config.ini	39
Rysunek 6.8: Definicja tabeli faktów fact_biblioteki z kluczami głównym i obcymi.	39
Rysunek 6.9: Zbiorczy zapis danych do tabeli stg_miary w ramach procesu ETL.	40
Rysunek 6.10: Fragment kodu realizujący mapowanie unit_id na kod TERYT w procesie ETL.	40
Rysunek 6.11: Tworzenie wymiaru czasu na podstawie lat występujących w danych źródłowych.....	41
Rysunek 6.12: Przebieg wykonania procesu tworzenia struktury bazy i ładowania danych.	42
Rysunek 6.21: Diagram aktywności pipeline’u ETL z uwzględnieniem modularnej architektury systemu.	43
Rysunek 6.22: Struktura pliku konfiguracyjnego config.ini	44
Rysunek 6.23: Mechanizm trybu testowego ograniczającego zakres pobierania danych.	45
Rysunek 6.24: Warunek zakończenia pobierania danych w trybie testowym.	45
Rysunek 6.25: Wyniki pomiaru czasu przy użyciu wersji plików wykorzystujących CSV i Parquet.	46
Rysunek 6.13: Warunek przerwania pętli pobierania danych w przypadku błędu odpowiedzi API.	47
Rysunek 6.14: Wyłączenie trybu autocommit i inicjalizacja transakcyjnego przetwarzania danych....	47
Rysunek 6.15: Zapis zmian do bazy danych po pomyślnym przetworzeniu danych.	47
Rysunek 6.16: Wycofanie zmian i zamknięcie połączenia w przypadku błędu procesu ETL.	48
Rysunek 6.17: Definicja klucza głównego oraz kluczy obcych w tabeli fact_biblioteki.	48
Rysunek 6.18: Mechanizm aktualizacji danych w tabeli fact_biblioteki.	49
Rysunek 6.19: Sekwencyjne wywołanie modułu pobierania danych i procesu ETL.....	50
Rysunek 6.20: Pomiar czasu wykonania procesu przetwarzania danych.....	50
Rysunek 7.1: Diagram ERD przedstawiający model danych w warstwie analitycznej.	53
Rysunek 7.2: Implementacja modelu danych w PowerBI.	55
Rysunek 7.3: Przykładowa strona raportu prezentująca kluczowe wskaźniki biblioteczne.....	56
Rysunek 7.4: Wykres liniowy prezentujący zmianę ilości wypożyczeń na jednego mieszkańca na przestrzeni lat.	58
Rysunek 7.5: Przykład porównania danych historycznych pomiędzy wybranymi latami.	58
Rysunek 7.6: Wykres przedstawiający ilość czytelników na 1 tys. mieszkańców na przestrzeni lat oraz wartości	60
Rysunek 7.7: Wykres przedstawiający porównanie trendów czytelnictwa dla poszczególnych typów gminy.	61

Rysunek 8.1: Weryfikacja kompletności zbioru danych.....	64
Rysunek 8.2: Weryfikacja unikalności rekordów w tabeli faktów.....	64
Rysunek 8.3: Weryfikacja kompletności transformacji w tabeli faktów.....	65
Rysunek 8.4: Strona raportu przedstawiająca wykresy zmiany liczby czytelników oraz wypożyczeń w wybranych latach.	66
Rysunek 8.5: Strona raportu zawierająca zestawienie liczby czytelników, oraz wypożyczeń w porównaniu z poziomem województwa oraz kraju	66
Rysunek 8.6: Wizualizacja modułu predykcyjnego i analizy trendów długookresowych.	67

Spis tabel

Tabela 4.1 Wymagania funkcjonalne.....	23
Tabela 4.2 Wymagania нефункционалне.....	24
Tabela 8.1 Wymagania нефункционалне.....	63

WYKAZ WAŻNIEJSZYCH OZNACZEŃ UŻYTYCH W PRACY

API – interfejs programistyczny aplikacji (Application Programming Interface)

BDL – Bank Danych Lokalnych Głównego Urzędu Statystycznego

PostgreSQL – relacyjny system zarządzania bazą danych

Power BI – narzędzie analityczno-wizualizacyjne klasy Business Intelligence

DAX – język formuł analitycznych stosowany w narzędziu Power BI (Data Analysis Expressions)

ERD – diagram związków encji (Entity Relationship Diagram)

ETL – proces ekstrakcji, transformacji i ładowania danych (Extract, Transform, Load)

GUS – Główny Urząd Statystyczny

KPI – kluczowy wskaźnik efektywności (Key Performance Indicator)

RMSE – pierwiastek średniego błędu kwadratowego (Root Mean Square Error)

SQL – strukturalny język zapytań do relacyjnych baz danych (Structured Query Language)

TERC – krajowy rejestr podziału terytorialnego kraju

TERYT – identyfikator jednostki terytorialnej

per capita – wskaźnik przeliczony na jednego mieszkańca

WYKAZ ZAŁĄCZNIKÓW

Załącznik 1. Kod źródłowy procesu ETL w języku Python:

- main_parquet.py - moduł sterujący.
- api_parquet.py - moduł ekstrakcji danych z API GUS BDL.
- etl_parquet.py - moduł transformacji i ładowania danych do bazy PostgreSQL.

Załącznik 2. Plik konfiguracyjny systemu (config.ini).

Załącznik 3. Plik raportu analitycznego Power BI (raport.pbix).

Załącznik 4. Plik requirements.txt

Załącznik 5. Plik Instrukcja_uruchomienia.pdf